

# 基于 GLMB 滤波和 Gibbs 采样的多扩展目标 有限混合建模与跟踪算法

陈一梅<sup>1</sup> 刘伟峰<sup>1,2</sup> 孔明鑫<sup>1</sup> 张桂林<sup>2</sup>

**摘要** 本文针对杂波条件下多扩展目标的状态估计, 目标个数估计, 扩展目标形状估计问题, 提出了一种基于标签随机有限集 (Labelled random finite sets, L-RFS) 框架下多扩展目标跟踪学习算法, 该学习算法主要包括两方面: 多扩展目标动态建模和多扩展目标的跟踪估计. 首先, 结合广义标签多伯努利滤波器 (Generalized labelled multi-Bernoulli, GLMB) 建立了扩展目标的量测有限混合模型 (Finite mixture models, FMM), 利用 Gibbs 采样和贝叶斯信息准则 (Bayesian information criterion, BIC) 准则推导出有限混合模型的参数来对多扩展目标形状进行学习, 然后采用等效量测方法来替代扩展目标产生的量测, 对扩展目标形状采用椭圆逼近建模, 实现扩展目标形状与状态的估计. 仿真实验表明本文所给的方法能够有效跟踪多扩展目标, 并且在目标个数估计方面优于 CBMeMBer 算法. 此外, 与标签多伯努利滤波 (LMB) 计算比较表明: GLMB 和 LMB 算法滤波估计精度接近, 二者精度高于 CBMeMBer 算法.

**关键词** 多扩展目标, 有限混合模型, 标签随机有限集, GLMB 滤波器, Gibbs 采样, BIC 准则

**引用格式** 陈一梅, 刘伟峰, 孔明鑫, 张桂林. 基于 GLMB 滤波和 Gibbs 采样的多扩展目标有限混合建模与跟踪算法. 自动化学报, 2020, 46(7): 1445–1456

**DOI** 10.16383/j.aas.c180077

## A Modeling and Tracking Algorithm of Finite Mixture Models for Multiple Extended Target Based on the GLMB Filter and Gibbs Sampler

CHEN Yi-Mei<sup>1</sup> LIU Wei-Feng<sup>1,2</sup> KONG Ming-Xin<sup>1</sup> ZHANG Gui-Lin<sup>2</sup>

**Abstract** In this paper, a new multiple extended target tracking learning algorithm based on labelled random finite sets (L-RFS) framework is proposed to estimate the number, shape and state of extended targets under clutter conditions. The algorithm mainly includes two aspects: multi-extended target dynamic modeling and multi-extended target tracking estimates. Firstly, a finite mixture model (FMM) of extended target is established under the generalized labelled multi-Bernoulli (GLMB) filter. Learning the parameters of finite mixture model by Gibbs sampling and Bayesian information criterion (BIC), and then equivalent point target measurements are used in place of the actual extended target measurements. Finally, the proposed ellipse approximation model is used to realize the estimation of the extended target shape. The simulation results show that the proposed algorithm can effectively track the multiple extended targets and it is superior to CBMeMBer algorithm in the estimation of the number of extended targets. In addition, comparison with LMB filter shows that: The filtering accuracy of the GLMB and LMB algorithms are close to each other, and the accuracy of both algorithms is higher than CBMeMBer algorithm.

**Key words** Multiple extended target, finite mixture models (FMM), labeled random finite sets (L-RFS), Generalized labelled multi-Bernoulli (GLMB) filter, Gibbs sampling, Bayesian information criterion (BIC)

**Citation** Chen Yi-Mei, Liu Wei-Feng, Kong Ming-Xin, Zhang Gui-Lin. A modeling and tracking algorithm of finite mixture models for multiple extended target based on the GLMB filter and gibbs sampler. *Acta Automatica Sinica*, 2020, 46(7): 1445–1456

收稿日期 2018-01-31 录用日期 2018-07-15  
Manuscript received January 31, 2018; accepted July 15, 2018  
国家自然科学基金 (61771177, 61333011), 江苏省自然科学基金项目 (BK20160148), 杭州电子科技大学优秀学位论文培育基金项目 (yx1w2018008) 资助  
Supported by National Nature Science Foundation of China (61771177, 61333011), Natural Science Foundation for Young Scientists of Jiangsu Province (BK20160148), Foundation for Hangzhou Dianzi University Excellent Dissertation Cultivation Project (yx1w2018008)  
本文责任编辑 许斌  
Recommended by Associate Editor XU Bin  
1. 杭州电子科技大学自动化学院系统科学与控制工程研究所 杭州

多目标跟踪在民用、军用等很多领域都存在着重要的应用意义. 传统目标跟踪的对象一般假设为点目标, 此类目标至多产生一个量测点. 但随着现

310018 2. 中国电子科技集团公司第二十八研究所信息系统工程重点实验室 南京 210007

1. Institute of Systems Science and Control Engineering, School of Automation, Hangzhou Dianzi University, Hangzhou 310018  
2. Science and Technology on Information System Engineering Laboratory, The 28th Research Institute of CETC, Nanjing 210007

代传感器技术的不断发展, 雷达分辨率的日益提高使得我们能够从单个目标中获得多个量测, 即一个目标在一个采样周期内产生不止一个量测点, 这类目标称为扩展目标<sup>[1]</sup>。如图 1 所示, 能够从目标的机身、机尾等容易反射雷达波的位置获得多个量测。扩展目标的跟踪能为我们提供被跟踪目标精确的运动信息和形态信息。



图 1 扩展目标 (“四角星” 表示量测)

Fig. 1 The concept map of extended target  
(the four-pointed star denotes the measurement)

扩展目标跟踪存在的问题: 1) 一个目标在一个采样周期内产生不止一个量测点, 并且这些量测通常位于传感器 (例如雷达) 同一个分辨单元内, 扩展目标个数估计具有一定难度; 2) 扩展目标的形状通常是未知的, 甚至可能随时间变化, 导致目标形状估计难度增大<sup>[2]</sup>。因为其不再满足点目标的假设条件, 如果依然采用传统的量测关联算法, 如概率数据关联 (Probabilistic data association, PDA) 算法<sup>[3]</sup>, 联合概率数据关联 (Joint probabilistic data association) 算法<sup>[4-5]</sup>, 多假设跟踪 (Multiple hypothesis tracking, MHT) 算法<sup>[6-7]</sup>, 随着目标个数和量测数的增加, 运算量将呈指数增长, 产生组合爆炸问题。

近年来, 随机有限集 (Random finite sets) 理论为扩展目标的跟踪问题提供了一种新的解决思路。传统的跟踪算法方面, 文献 [8] 中, Koch 引进了不可分辨扩展目标的概念并且结合随机矩阵理论<sup>[9]</sup> 提出了基于经典贝叶斯框架的扩展目标跟踪算法, 该算法将单点源目标跟踪算法扩展到单个扩展目标跟踪, 可以得到扩展目标的形心点, 同时通过估计二阶矩获得扩展目标的近似椭圆形状, 但该方法仅适用于无杂波环境下单个扩展目标的跟踪。Baum 在文献 [10] 中引进了随机超曲面模型, 假设每个测量源是随机生成的超曲面的元素, 通过椭圆形目标形状证明了该模型的适用性。在文献 [11-12] 中, Gilholm 等提出基于泊松分布的扩展目标模型。Mahler 提出了 ET-PHD 扩展目标概率假设密度<sup>[13]</sup>, 该方法不再需要数据关联, 可以同时获得目标状态估计和个数估计。文献 [14] 提出了一种高斯混合 PHD 扩

展目标跟踪算法。随后 Orguner 等引出针对扩展目标的 E-CPHD 势概率假设密度算法<sup>[15]</sup>。Vo 等在文献 [16] 中提出了广义标签多伯努利 (Generalized labelled Multi-Bernoulli, GLMB) 滤波多目标跟踪算法, 该算法能够标记不同的目标轨迹, 但是计算成本也相对较高。在 GLMB 滤波算法基础上, Beard 基于单个扩展目标, 结合 GLMB 滤波和伽马-高斯-逆 Wishart (GGIW) 分布扩展到多个扩展目标跟踪算法<sup>[17]</sup>。对于多扩展目标跟踪问题难点在于其目标个数的估计, 文献 [18] 对原始 CBMeMBer 滤波算法的更新步进行了改进, 引入多量测似然函数, 避免了对目标数目的过估计。针对扩展目标的形状估计, 文献 [19] 提出了扩展目标形状跟踪的星凸形超曲面模型, 在此前, 已经有椭圆或矩形模型、棍形、随机矩阵模型<sup>[20]</sup> 和椭圆随机超曲面模<sup>[21-23]</sup> 来对扩展目标形状建模。对于 Gibbs 采样的应用, Vo 等将 GLMB 滤波的更新步和预测步积分处理成一步, 提出了一种基于 Gibbs 采样的截断广义标签多伯努利滤波密度的有效处理方法<sup>[24-25]</sup>。文献 [26] 提出一种基于变分贝叶斯的势均衡多目标多伯努利滤波 (VB-CBMeMBer) 跟踪算法, 利用变分贝叶斯方法近似地求出各量测产生点状态和量测噪声协方差的联合概率密度, 将得到量测产生的点状态进行聚类得到扩展目标的状态。

对于单目标的多量测问题, 文献 [27] 中已经做过相关研究, 通过建立目标形状的参数模型, 采用参数马尔科夫链采样的方法来对目标的形状进行估计, 但该方法基于传统的 Bayes 框架, 不能处理目标出生死亡情况和目标个数变化情况。而扩展目标跟踪问题某种程度上类似于群目标, 都需要考虑多量测情况, 文献 [28] 对可分辨群目标的跟踪, 采用基于 GLMB 滤波来估计群成员中各目标状态, 通过邻接矩阵得到群的结构和个数估计, 这对本文的研究有一定的启发。

对于多扩展目标的跟踪问题, 我们采用 GLMB 滤波器来估计杂波中的多个扩展目标, 文献 [17] 中提出的带标签的多伯努利 (LMB) 滤波器的关键原则是为了减少算法的计算复杂度, 速度较快, 在每次迭代后简化多目标密度的表示, 而不是保持从一个周期到下一个周期的完整 GLMB 后验分布, 在测量更新步骤之后它近似为 LMB 分布, 由于 LMB 滤波器在每次更新后都进行近似处理, 因此它会在基数分布中产生累积误差, 与 GLMB 滤波器相比, 这会导致估计误差增加。

本文重点研究多扩展目标的学习算法, 基于扩展目标 GLMB 滤波, 建立目标量测有限混合模型, 将 Gibbs 采样和 BIC (Bayesian information criterion) 准则结合来对多扩展目标进行学习跟踪,

利用量测等效方法替代扩展目标产生的量测, 对扩展目标的形状采用椭圆建模和状态估计.

本文是文献 [29] 的后续研究工作, 文献 [29] 只给出了扩展目标的动态建模方法以及获得扩展目标状态估计方法. 本文在文献 [29] 的基础上对扩展目标的量测有限混合模型进行了更详细的说明, 建立多扩展目标关联图, 给出了杂波条件下多扩展目标的个数估计, 实验仿真部分给出了 GLMB 算法和 CBMeMBer 算法对于多扩展目标跟踪的对比实验, 实验结果较于文献 [29] 更为全面.

本文的结构为: 第 1 节介绍了标签随机有限集和 FMM (Finite mixture model) 有限混合模型的理论基础; 第 2 节给出了多扩展目标的跟踪学习算法, 包括扩展目标的 GLMB 滤波, 扩展目标有限混合模型, Gibbs 采样结合 BIC 准则的算法介绍; 第 3 节为实验的仿真分析; 第 4 节为论文总结.

## 1 问题描述

多扩展目标跟踪问题不同于一般的多目标跟踪问题, 单个扩展目标往往产生多个量测, 并且量测之间的距离很小. 传统多目标跟踪算法不再适用, 为此本文采用基于标签随机有限集的跟踪算法, 建立目标量测有限混合模型, 通过提出的采样算法来对多扩展目标进行学习. 对于扩展目标的多个量测, 建立量测有限混合模型和 Gibbs 采样学习算法.

### 1.1 标签随机有限集 (L-RFS)

在随机有限集的框架下, 元素的个数是随机的, 元素本身也是随机的, 元素之间没有先后顺序之分. 多目标在  $k$  时刻的状态可以用下面的 RFS (Random finite sets) 集合表示<sup>[30-31]</sup>:

$$X_k = \{x_{k,1}, \dots, x_{k,N(k)}\} \in \mathcal{F}(\mathcal{X}) \quad (1)$$

随着时间的变化, 状态集包含了  $k$  时刻多目标的所有动态信息, 在下一时刻, 目标可能会再新生出新的未知目标, 目标可能持续存活, 目标可能死亡, 目标 RFS 的状态模型可以写成如下形式:

$$X_k = \Gamma_k \cup [\cup_{x \in X_{k-1}} B_{k|k-1}(x)] \cup [\cup_{x \in X_{k-1}} S_{k|k-1}(x)] \quad (2)$$

其中,  $S_{k|k-1}(x)$ 、 $B_{k|k-1}(x)$  和  $\Gamma_k$  分别表示目标的存活、再生和新生 RFS.

观测 RFS 的建立同样如下表示:

$$Z_k = \{z_{k,1}, \dots, z_{k,M(k)}\} \in \mathcal{F}(\mathcal{Z}) \quad (3)$$

$Z_k^e \subseteq Z_k$ ,  $Z_k^e$  表示扩展目标在  $k$  时刻的量测集,  $Z_k^e = \{Z_{k,1}^e, \dots, Z_{k,n_k}^e\}$ , 其中  $Z_{k,n_k}^e$  表示第  $n_k$  个扩展目标在  $k$  时刻产生的量测集.

RFS  $Z_k$  包含了杂波、目标观测和漏检信息, 这里的目标观测包含扩展目标的观测值,  $N(k)$  和  $M(k)$  分别表示  $k$  时刻目标和量测的个数,  $\mathcal{F}(\mathcal{X})$  和  $\mathcal{F}(\mathcal{Z})$  分别表示  $\mathcal{X}$  和  $\mathcal{Z}$  的所有有限子集构成的集合. 总量测集合由目标量测、未知杂波产生的量测、虚警量测组成, 其量测 RFS 可以用下面这个式子表示:

$$Z_k = [\cup_{x \in X_k} \Theta_k(x)] \cup K_k \quad (4)$$

不同于传统的 RFS, 标签 RFS 在目标状态向量  $x \in X$  添加了标签  $\ell \in L = \{\alpha_i : i \in \mathbf{N}\}$  变量, 标签状态向量是一个有限集且定义在  $X \times L$  上, 扩展目标的状态  $(x, \ell)$ , 多扩展目标在  $k$  时刻的带标签状态为  $\mathbf{X}_k = \{(x_k, \ell_1), \dots, (x_k, \ell_n)\}$ , GLMB 滤波算法要求不同目标的标签是不同且唯一的, 因此, 用下述表达式作为标签约束条件:

$$\Delta(\mathbf{X}) = \begin{cases} 1, & |\mathcal{L}(\mathbf{X})| = |\mathbf{X}| \\ 0, & |\mathcal{L}(\mathbf{X})| \neq |\mathbf{X}| \end{cases} \quad (5)$$

其中,  $\mathcal{L}(\mathbf{X}) = \{\mathcal{L}(\mathbf{x}) : \mathbf{x} \in \mathbf{X}\}$  是  $\mathbf{X}$  的标签集,  $\mathcal{L}(\mathbf{x}) = \mathcal{L}((x, \ell))$ . RFS  $\mathbf{X}$  满足  $\Delta(\mathbf{X}) = 1$ , 标签空间  $L$  是离散分布的.

标签多伯努利的密度函数如下公式所示<sup>[32]</sup>:

$$\pi(\{(x_1, \ell_1), \dots, (x_n, \ell_n)\}) = \delta_n(|\{\ell_1, \dots, \ell_n\}|) \prod_{\zeta \in \Psi} (1 - r^{(\zeta)}) \times \prod_{j=1}^n \frac{1_{\alpha(\Psi)}(\ell_j) r^{(\alpha^{-1}(\ell_j))} p^{(\alpha^{-1}(\ell_j))}(\mathbf{x}_j)}{1 - r^{(\alpha^{-1}(\ell_j))}} \quad (6)$$

其标签多伯努利简化形式为:

$$\pi(\mathbf{X}_I) = \Delta(\mathbf{X}_I) 1_{\alpha(\Psi)}(\mathcal{L}(\mathbf{X}_I)) [p(\cdot)]^{\mathbf{X}_I} \quad (7)$$

### 1.2 目标关联图

对于 GLMB 滤波算法, 在 RFS 多目标似然函数的分析中关联图有着至关重要的作用.

**定义 1**<sup>[16]</sup>. 所谓关联图就是一个映射:  $v: L \rightarrow \{0, 1, \dots, |Z|\}$ , 如果  $v(i) = v(i') > 0$ , 意味着  $i = i'$ , 集合  $V$  表示关联图空间, 其子集  $I$  可以用  $V(I)$  表示. 关联图描述了目标与量测之间的对应关系, 即: 目标  $l$  产生的量测为  $z_{v(l)} \in Z$ , 对于没有被检测到的目标我们用 0 来标记.

假设杂波与目标量测的检测是彼此独立的, 多目标似然函数表示如下公式:

$$g(Z|X) = e^{-\langle k, 1 \rangle} k^Z \sum_{v \in V(\mathcal{L}(X))} [\psi_Z(\cdot; v)]^X \quad (8)$$

其中

$$\psi_Z(x, l; v) = \begin{cases} \frac{p_D(x, l)g(z_{v(l)}|x, l)}{k(z_{v(l)})}, & v(l) > 0 \\ 1 - p_D(x, l), & v(l) = 0 \end{cases} \quad (9)$$

### 1.3 有限混合模型 (FMM)

有限混合模型通常用来描述各种随机源产生的量测集  $Z = \{z_1, \dots, z_n\}$ <sup>[33]</sup>,  $f(z_i|\Theta)$  表示混合密度, 其中  $\Theta$  是混合分布的参数集. 显然很难直接对混合密度进行推导, 将指示变量  $e_i \in \{1, 2, \dots, n\}$  加入混合密度, 当  $e_i = j$  时, 它表示来源于第  $j$  个分布的第  $i$  个量测  $z_i$ , 根据全概率公式得出混合密度的形式如下所示:

$$f(z_i|\Theta) = \sum_{j=1}^m f(z_i|\Theta, e_i = j)P(e_i = j|\Theta) \quad (10)$$

进一步推导, 可以得出

$$f(z_i|\Theta) = \omega_1 f(z_i|\theta_1) + \dots + \omega_m f(z_i|\theta_m) \quad (11)$$

其中, 混合分布的参数集  $\Theta = \{p\omega_1, \dots, \omega_m, \theta_1, \dots, \theta_m\}$ ,  $\{\theta_1, \dots, \theta_m\}$  是单个分布元素的参数,  $\{\omega_1, \dots, \omega_m\}$  是每个元素的混合权重, 由下式定义:

$$\omega_j = P(e_i = j|\Theta) \quad (12)$$

本文杂波分布为均匀分布, 杂波密度函数如式 (13) 所示:

$$c_k(z_k^c) = \frac{\lambda_c}{V(S)} \quad (13)$$

其中,  $V(S)$  表示杂波分布的区域面积,  $\lambda_c$  为杂波强度.

## 2 多扩展目标学习跟踪算法

### 2.1 扩展目标有限混合模型 (E-FMM)

有限混合模型 (FMM) 主要解决的问题是如何从量测数据中推算两类模型参数: 随机源个数, 每个随机源的分布参数. 在扩展目标跟踪方面, 多扩展目标和杂波属于典型的多类随机源, 也需要解决同样的问题, 因此, FMM 可以有效描述多扩展目标与杂波干扰的混合量测特性. 传统的扩展目标建模, 按照量测集, 主要采用单高斯分布描述每个扩展目标, 并且也没有引入模型评价指标. 相对于传统的方法, 采用 FMM 更适合描述多扩展目标和杂波同时存在的情况.

在  $k$  时刻, 扩展目标量测集  $Z_k^e = \{Z_{k,1}^e, \dots, Z_{k,n_k}^e\}$ , 它的混合分布函数如下公式:

$$f(Z_k^e|\Theta_k^e) = \omega_{k,1}^e f(Z_{k,1}^e|\theta_{k,1}^e) + \dots + \omega_{k,m_k^e}^e f(Z_{k,i}^e|\theta_{k,m_k^e}^e) \quad (14)$$

其中,  $\omega_{k,m_k^e}^e$  表示扩展目标的第  $m_k^e$  个量测的混合权重,  $\theta_{k,m_k^e}^e$  表示第  $m_k^e$  个量测的参数集.

假设多扩展目标的分布为一个均匀杂波分布和多个高斯分布组成,  $Z_k^e \subseteq Z_k$ ,  $Z_k = Z_k^e \cup Z_k^c$ ,  $Z_k^c$  表示均匀杂波量测集, 则多扩展目标混合分布可以写成下式所示:

$$f(z_{k,i}|\Theta_k) = \omega_{k,1} U(z_{k,i}|V_k) + \omega_{k,2} N(z_{k,i}; \mu_{k,2}, D_{k,2}) + \dots + \omega_{k,m_k} N(z_{k,i}; \mu_{k,m_k}, D_{k,m_k}) \quad (15)$$

其中,  $\theta_{k,m_k} = \{\mu_{k,m_k}, D_{k,m_k}\}$ . 扩展目标估计可以通过下面的贝叶斯方程来表述:

$$p(\Theta_k|Z_k^e) \propto g(Z_k^e|\Theta_k)p(\Theta_k) \quad (16)$$

假设各量测之间是相互独立的, 则量测似然函数用式 (17) 来表示:

$$g(Z_k^e|\Theta_k) = \prod_i^{n_k} f(z_{k,i}|\Theta_k) = \prod_i^{n_k} [\omega_1 U(z_{k,i}) + \sum_{j=2}^{m_k} \omega_j N(z_{k,i}; \mu_{k,j}, D_{k,j})] \quad (17)$$

其中,  $\Theta_k = \{\omega_{k,1}, \omega_{k,j}, \mu_{k,j}, D_{k,j}\}_{j=2}^{m_k}$ , 扩展目标参数先验是联合分布, 直接估计单个参数比较困难, 所以采用条件分布的形式:

$$p(\Theta_k) = p(m_k)p(\omega_k|m_k)p(D_k|\omega_k, m_k) \times p(\mu_k|D_k, \omega_k, m_k) \quad (18)$$

其中,  $\omega_k := \{\omega_{k,1}, \dots, \omega_{k,m_k}\}$ ,  $\mu_k := \{\mu_{k,1}, \dots, \mu_{k,m_k}\}$ ,  $D_k := \{D_{k,2}, \dots, D_{k,m_k}\}$  分别表示混合权重集、均值向量集、协方差集. 进一步推导  $p(\Theta_k)$  的先验分布如下公式所示:

$$p(\Theta_k) = p(\omega_{k,1}) \prod_{j=2}^{m_k} [p(\omega_{k,j})p(D_{k,j})p(\mu_{k,j}|D_{k,j})] \quad (19)$$

其中

$$p(\omega_{k,1}, \dots, \omega_{k,m_k}) = D\left(\frac{1}{m_k}, \dots, \frac{1}{m_k}\right) \quad (20)$$

$$p(D_{k,j}) = W(\beta_{k,j}, I) \quad (21)$$

$$p(\mu_{k,j} | D_{k,j}) = N(\mu_{k,j}; \hat{\mu}_{k,j}, D_{k,j}) \quad (22)$$

$$p(D_{k,j}^c) = W(\beta_{k,j}^c, I) \quad (23)$$

$D$  表示为 Dirichlet 分布,  $W$  表示为 Wishart 分布,  $\beta$  为 Wishart 分布的自由度,  $\hat{\mu}_{k,j}$  为第  $j$  个扩展目标的先验均值.

推导得出, 参数的后验分布如下公式:

$$p(\Theta_k | Z_k) = p(\omega_k | Z_k) p(D_k | \omega_k, Z_k) \times p(\mu_k | D_k, \omega_k, Z_k) \quad (24)$$

协方差矩阵服从自由度为  $\beta_{k,j}$  的逆 Wishart 分布, 其中相关的条件后验分步如下公式所述:

$$p(\omega_1, \dots, \omega_{m_k}) = D(a_1 + l_1, \dots, a_{m_k} + l_{m_k}) \quad (25)$$

$$p(D_j | D \setminus D_j, w, Z_k) = W(\alpha_0 + l_j / M_0, \beta_0 + K_j / N_0) \quad (26)$$

$$p(\mu_j | \mu \setminus \mu_j, D, w, Z_k) = N(\mu_j; \xi_j, D_j) \quad (27)$$

其中,  $M_0, N_0, \alpha_0, \beta_0, \{a_1, \dots, a_{m_k}\}$  均为先验参数, 为先验分布的常量. 参数  $l_j, \xi_j, K_j^2$  由下式推导得出<sup>[34]</sup>.

$$l_j = \sum_i e_{i,j} \quad (28)$$

$$e_{i,j} = \frac{w_j N(z_k; \mu_j, D_j)}{f(z_{k,i} | \Theta_k)}, \quad j \geq 2 \quad (29)$$

$$\xi_j = \frac{\sum_i e_{i,j} z_k}{l_j} \quad (30)$$

$$K_j^2 = \frac{\sum_i (z_{k,i} - \xi_j)(z_{k,i} - \xi_j)^T e_{i,j}}{l_j} \quad (31)$$

其中,  $e_{i,j}$  为扩展目标量测集的指示变量.

$l_j$  为第  $j$  个分布的观测个数,  $e_{i,j}$  作为指示变量的估计值,  $\xi_j$  为第  $j$  个分布的统计均值,  $K_j^2$  为二阶矩值.

## 2.2 扩展目标 GLMB 滤波

### 2.2.1 多扩展目标关联图

假设多扩展目标量测可以用  $Z_k^e = \{Z_{k,1}^e, \dots, Z_{k,n_k}^e\} \in \mathcal{F}(\mathcal{Z})$  表示, 其中,  $Z_{k,n_k}^e$  表示第  $n_k$  个扩展目标在  $k$  时刻产生的量测集:

$$Z_{k,n_k}^e = \{z_{k,1}, \dots, z_{k,N(k)}\} \quad (32)$$

本文通过建立量测有限混合模型, 采用学习算法得出扩展目标的等效量测集:

$$\hat{Z}_k = \{\hat{z}_{k,1}, \dots, \hat{z}_{k,n_k}\} \quad (33)$$

其中,  $\hat{z}_{k,n_k}$  表示  $k$  时刻下的第  $n_k$  个扩展目标的等效量测.

**定义 2**<sup>[17]</sup>. 多扩展目标关联图是一个映射:  $v_e: L \rightarrow \{0, 1, \dots, |\hat{Z}_k|\}$ , 如果  $v_e(i) = v_e(i') > 0$ , 意味着  $i = i'$ , 集合  $V_e$  表示多扩展目标关联图空间, 其子集  $I$  可以用  $V_e(I)$  表示. 关联图描述了扩展目标  $l$  与量测之间的对应关系, 即: 目标  $l$  产生的量测为  $z_{v_e(l)} \in Z$ , 对于没有被检测到的扩展目标我们用 0 来表示.

同样假设杂波与目标量测的检测彼此独立, 多扩展目标似然函数表示如下公式所示:

$$g(\hat{Z}_k | X) = e^{-\langle k, 1 \rangle} k^{\hat{Z}_k} \sum_{v_e \in V_e(\mathcal{L}(X))} [\psi_{\hat{Z}_k}(\cdot; v_e)]^X \quad (34)$$

其中

$$\psi_{\hat{Z}_k}(x, l; v_e) = \begin{cases} \frac{p_D(x, l) g(z_{v_e(l)} | x, l)}{k(z_{v_e(l)})}, & v_e(l) > 0 \\ 1 - p_D(x, l), & v_e(l) = 0 \end{cases} \quad (35)$$

多扩展目标后验概率为:

$$\pi(X | Z_k^e) = \frac{g(Z_k^e | X) \pi(X)}{\int g(Z_k^e | X) \pi(X) \delta X} \quad (36)$$

其中函数分母  $f$  的集合积分定义如下:

$$\int f(X) \delta X = \sum_{i=0}^{\infty} \frac{1}{i!} \sum_{(\ell_1, \dots, \ell_n) \in L^i} \int_{X^i} f(\{x_1, \ell_1\}, \dots, \{x_i, \ell_i\}) d(x_1, \dots, x_i) \quad (37)$$

不同的时段, 单个扩展目标可能产生不止一个量测, 各个扩展目标的产生的量测个数也都是不确定的, 要在不同时刻对量测进行判断: 不同量测到底属于哪一个扩展目标, 在得到扩展目标的一组量测后建立量测有限混合模型, 通过学习算法学习出扩展目标量测的形心, 然后利用等效量测替代的思想来实现扩展目标的 GLMB 滤波估计算法.

### 2.2.2 GLMB 估计算法

使用 GLMB 滤波算法对多扩展目标进行跟踪, GLMB 滤波主要分为两步: 预测步和更新步. 扩展目标状态  $(x, \ell)$ , 目标被检测到的概率为  $p_D(x, \ell)$ , 则目标未被检测到的到概率为  $q_D(x, \ell) = 1 - p_D(x, \ell)$ ,

标准 GLMB 滤波算法在贝叶斯递推下封闭, 其算法定义如下<sup>[17, 35]</sup>:

$$\pi(\mathbf{X}) = \Delta(\mathbf{X}) \sum_{c \in C} \omega^{(c)}(\mathcal{L}(\mathbf{X})) [p^{(c)}]^{\mathbf{X}} \quad (38)$$

为便于计算, 上述公式可以写成如下形式, 称为  $\delta$ -GLMB:

$$\pi(\mathbf{X}) = \Delta(\mathbf{X}) \sum_{(I, \xi) \in F(L) \times \Xi} \omega^{(I, \xi)} \delta_I(\mathcal{L}(\mathbf{X})) [p^{(\xi)}]^{\mathbf{X}} \quad (39)$$

如果目标的先验分布为上述  $\delta$ -GLMB 分布, 则多扩展目标的预测步如下所示:

$$\pi_+(\mathbf{X}_+) = \Delta(\mathbf{X}_+) \sum_{(I_+, \xi) \in F(L) \times \Xi} \omega_+^{(I_+, \xi)} \times \delta_{I_+}(L(\mathbf{X}_+)) [p_+^{(\xi)}]^{\mathbf{X}_+} \quad (40)$$

其中

$$\omega_+^{(I_+, \xi)} = \omega_B(I_+ \cap B) \omega_S^\xi(I_+ \cap L) \quad (41)$$

$$p_+^{(\xi)}(x, l) = 1_L(l) p_S^\xi(x, l) + (1 - 1_L(l)) p_B(x, l) \quad (42)$$

$$p_S^{(\xi)}(x, l) = \frac{\langle p_S(\cdot, l) f(x|\cdot, l), p^{(\xi)}(\cdot, l) \rangle}{\eta_S^{(\xi)}(l)} \quad (43)$$

$$\eta_S^\xi(l) = \int \langle p_S(\cdot, l) f(x|\cdot, l), p^{(\xi)}(\cdot, l) \rangle dx \quad (44)$$

$$\omega_S^{(\xi)}(L) = [\eta_S^{(\xi)}]^L \sum_{I \subseteq L} 1_I(L) [q_S^{(\xi)}]^{I-L} \omega^{(I, \xi)} \quad (45)$$

$$q_S^{(\xi)}(l) = \langle q_S(\cdot|l), p^{(\xi)}(\cdot, l) \rangle \quad (46)$$

其中, 新生标签  $I_+ \cap B$  的权重通过  $\omega_B(I_+ \cap B)$  来表示, 存活标签权重  $\omega_S^\xi(I_+ \cap L)$ , 存活目标的概率密度  $f(\cdot|\cdot, l)$ , 新生目标概率密度  $p_B(\cdot, l)$ , 由先验密度  $P^\xi(\cdot, l)$  得到的存活目标密度  $P_S^\xi(x, l)$ .

如果多目标的先验如式 (39) 所示, 则更新步如下所示, 在更新步中, 需要对多扩展目标产生的多个量测进行组合划分, 但其组合事件个数较多, 采用预测方法精度不足, 本文采用 Gibbs 采样迭代学习算法来实现:

$$\pi(\mathbf{X}|Z) \approx \Delta(\mathbf{X}) \sum_{(I, \xi) \in F(L) \times \Xi} \sum_{\theta \in \Theta} \tilde{\omega}^{(I, \xi, \theta)} \times \delta_I(L(\mathbf{X})) [p^{(\xi, \theta)}]^{\mathbf{X}} \quad (47)$$

其中  $\theta$  代表当前量测的关联图子集, 相关的参数定义如下.

$$w^{(I, \xi, \theta)}(Z) = \frac{\delta_{\theta^{-1}(\{0:|Z|\})}(I) w^{(I, \xi)} \left[ \eta_Z^{(\xi, \theta)} \right]^I}{\sum_{(I, \xi) \in F(L) \times \Xi} \sum_{\theta \in \Theta} \delta_{\theta^{-1}(\{0:|Z|\})}(I) w^{(I, \xi)} \left[ \eta_Z^{(\xi, \theta)} \right]^I} \quad (48)$$

$$p^{(\xi, \theta)}(x, l|Z) = \frac{p^{(\xi)}(x, l) \psi_Z(x, l; \theta)}{\eta_Z^{(\xi, \theta)}(l)} \quad (49)$$

$$\eta_Z^{(\xi, \theta)}(l) = \langle p^{(\xi)}(\cdot, l) \psi_Z(\cdot, l; \theta) \rangle \quad (50)$$

$$\psi_Z(x, l; \theta) = \delta_0(\theta(l)) q_D(x, l) + (1 - \delta_0(\theta(l))) \times \frac{p_D(x, l) g(z_{\theta(l)}|x, l)}{k(z_{\theta(l)})} \quad (51)$$

在获得目标状态估计基础上, 进一步学习出扩展目标的形状.

### 2.3 扩展目标形状估计

本文采用 Gibbs 采样算法估计高斯分布的均值协方差及各个高斯分布的权重, 然后利用 BIC 准则来判断几个高斯分布的拟合真实程度. 对扩展目标形状采用椭圆建模, 以均值替代扩展目标的中心量测即椭圆的中心点, 不断学习出扩展目标的形状. 本文学习算法流程如下所示:

**算法 1.** 扩展目标学习算法步骤

- 1) 当  $k = 1$
- 2) GLMB 预测过程
- 3) Gibbs 采样算法, BIC 评价
- 4) 获取扩展目标量测
- 5) 计算等效量测, 替换扩展量测
- 6) GLMB 更新过程
- 7)  $k = k + 1$

Geman 等在文献 [36] 中提出了 Gibbs 采样算法, Gibbs 采样需要知道样本中一个属性在其他所有属性下的条件概率, 然后利用这个条件概率来推导出各个属性的样本值. Gibbs 采样可以在给定协方差数据和参数的先验分布条件下获得参数的后验分布样本. 本文在 Gibbs 采样的基础上, 结合贝叶斯信息准则 (BIC) 来评价扩展目标有限混合模型和真实数据分布的匹配度. 其物理含义意味着用简单的模型来表达更多的信息. BIC 准则定义如下:

$$BIC(m_k, \Theta_k, Z_k) = -2 \ln L(\Theta_k, m_k | Z_k) + M_k \ln(n_k) \quad (52)$$

其中,  $M_k$  是独立参数的个数,  $\ln L(\Theta_k, m_k | Z_k)$  表示参数集  $\Theta_k$  和元素个数  $m_k$  的对数似然函数。

$$M_k = 3m_k + 2 \quad (53)$$

$$L(\Theta_k, m_k | Z_k) = \prod_{i=1}^{n_k} f(z_{k,i}, m_k) \quad (54)$$

当 BIC 值取最小时, 优先考虑扩展目标元素的个数估计,  $m_k$  值和参数学习过程相关。一旦学习过程达到稳定便停止学习过程, 扩展目标的参数估计由下式推导:

$$\{\hat{m}_k, \hat{\Theta}_k\} = \operatorname{argmin}_{\{m_k, \Theta_k\}} BIC(m_k, \Theta_k) \quad (55)$$

扩展目标混合模型:

$$f(z_{k,i} | \hat{m}_k, \hat{\Theta}_k) \propto w_{k,1} U(S_k) + \sum_{m=2}^{\hat{m}_k} w_m N(z_{k,i}, \mu_{k,m}, D_{k,m}) \quad (56)$$

在文献 [37] 基于 BIC 准则和 Gibbs 采样的时变杂波估计算法的基础上, 本文实现了对扩展目标的跟踪学习。Gibbs 采样算法, BIC 评价步骤如下所示:

#### 算法 2. Gibbs & BIC 算法

1) Gibbs 采样:

$h = 0, \mu_j \sim U(S), D_j = S^{\frac{1}{z_{\dim}}} I / 4$

当  $h = 0 \sim I, I = 20$  时,

$t = t + 1$

$(\omega_{k,1}, \dots, \omega_{k,m}) \sim D(a_1 + l_{k,1}^{(t-1)}, \dots, a_m + l_{k,m}^{(t-1)})$

当  $j = 1: m$  时,

$\mu_{i,j}^{(h)} = N(z_{k,i}; \mu_{k,j}^{(t-1)}, D_{k,j}^{(t-1)})$

$e_{i,j}^{(h)} = \omega_j \mu_{i,j}^{(h)} / \sum_j \omega_j \mu_{i,j}^{(h)}$

$l_j^{(h)} = \sum_i e_{i,j}^{(h)}$

$\xi_j^{(h)} = \sum_i e_{i,j}^{(h)} z_{k,i} / l_j^{(h)}$

$K_j^{(h)2} = \sum_i (z_{k,i} - \xi_j^{(h)}) (z_{k,i} - \xi_j^{(h)})^T e_{i,j}^{(h)} / l_j^{(h)}$

$D_j^{(h)-1} \sim W(I + K_j^{(h)2} / 2, \beta_0 + l^h / 2)$

$\mu_j^{(h)} \sim N(\xi_j^{(h)}, D_j^{(h)})$

2) BIC 计算:  $BIC(m_k, \Theta_k, Z_k) = -2 \ln L \times$

$(\Theta_k, m_k | Z_k) + 2 M_k \ln(n_k)$

输出:  $\{\omega_j^{(h)}, \mu_j^{(h)}, D_j^{(h)}, BIC(m), \hat{z}_{k,n_k}\}$

通过上述算法, 输出得到权重、均值、协方差和 BIC 值, 采用第  $n_k$  个扩展目标的等效量测  $\hat{z}_{k,n_k}$  替代该扩展目标量测, 对扩展目标形状采用椭圆逼近建模, 通过 Gibbs 参数学习算法不断学习出扩展目标的形状。

### 3 仿真实现

通过线性高斯场景比较 GM-GLMB、GM-CBMeMBer<sup>[38]</sup> 两种滤波算法对多扩展目标数目

和状态的估计性能。

#### 3.1 仿真实验比较

假设在含有杂波的观测区域内有 4 个扩展目标在运动, 目标数目时刻变化, 目标被检测到的概率为  $p_D = 0.98$ , 杂波为均匀分布, 杂波强度  $\lambda_c = 30$ , 杂波区域  $S = [-1000, 1000] \times [-1000, 1000] \text{ m}^2$ , 4 个扩展目标强度分别为:  $\lambda_{e1} = 16, \lambda_{e2} = 18, \lambda_{e3} = 20, \lambda_{e4} = 18$ . 扩展目标在 2 维平面做匀速直线 (Constant velocity, CV) 运动, 检测时间为 100 s. 在不同的时间, 不同的地点, 4 个扩展目标分别出生和消亡. 扩展目标 1 的存活时间假设为  $[1 \sim 70] \text{ s}$ , 扩展目标 2 的存活时间假设为  $[1 \sim 100] \text{ s}$ , 扩展目标 3 的存活时间假设为  $[20 \sim 80] \text{ s}$ , 扩展目标 4 的存活时间假设为  $[40 \sim 100] \text{ s}$ .

目标的状态方程为:

$$x_{k+1,i} = Gx_{k,i} + v_{k,i} \quad (57)$$

其中, 状态转移矩阵为:

$$G = \begin{bmatrix} 1 & T & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & T \\ 0 & 0 & 0 & 1 \end{bmatrix} \quad (58)$$

其中,  $T = 1 \text{ s}$  表示采样时间,  $x_k = [q_{k,x} \ \dot{q}_{k,x} \ q_{k,y} \ \dot{q}_{k,y}]^T$  分别表示  $x$  和  $y$  方向上的位置和速度。

目标的观测方程为:

$$z_{k+1,i} = Hx_{k,i} + \omega_{k,i} \quad (59)$$

其中, 观测矩阵  $H = [1 \ 0 \ 0 \ 0; 0 \ 0 \ 1 \ 0]$ , 观测噪声协方差为  $\text{diag}\{[10; 10]\} \times \text{diag}\{[10; 10]\}$ ,  $i$  表示第  $i$  个目标。4 个扩展目标的初始状态分别为:

$$\begin{aligned} x_1 &= [800 \text{ m}, -15 \text{ m/s}, 800 \text{ m}, -11 \text{ m/s}]^T \\ x_2 &= [800 \text{ m}, -10 \text{ m/s}, -600 \text{ m}, 5 \text{ m/s}]^T \\ x_3 &= [-800 \text{ m}, 20 \text{ m/s}, 400 \text{ m}, -5 \text{ m/s}]^T \\ x_4 &= [-200 \text{ m}, 15 \text{ m/s}, 800 \text{ m}, -10 \text{ m/s}]^T \end{aligned} \quad (60)$$

在整个跟踪过程中, 假设 4 个扩展目标是相互独立的, 图 2 表示 4 个扩展目标的运动真实轨迹, 图中不同的曲线分别表示 4 个扩展目标的各自运动轨迹, 扩展目标运动起点通过小圆圈来标记, 运动终点通过小三角来标记。

由 GLMB 滤波算法和 CBMeMBer 滤波算法得到的轨迹估计分别如图 3 和图 4 所示。GLMB 算法为每个目标添加了不同且唯一的标签, 以识别不同目标的身份标签, 可以得到如图 3 所示的各个目

标的轨迹估计, 而 CBMeMber 滤波算法获得点集航迹, 如图 4 所示, 目标的运动轨迹由独立的圆圈组成, 因此不能获得目标航集.




图 2 多扩展目标运动真实轨迹

Fig. 2 Ground truths for multiple extended targets




图 3 由 GLMB 滤波器得到的轨迹估计

Fig. 3 Track estimation by GLMB filter

图 5 所示为多扩展目标的状态估计, 不同颜色的轨迹代表不同扩展目标运动轨迹估计, 上图表示的是在  $x$  轴方向的跟踪轨迹, 下图表示在  $y$  轴方向上的跟踪轨迹. 在第 1s 时, 第 1 个和第 2 个扩展目标出现, 第 20s 时第 3 个扩展目标出现, 第 40s 时, 第 4 个扩展目标出现, 第 100s 时, 仅存在第 2 和第 4 个扩展目标, 由图 5 可以看出估计点与真实轨迹基本吻合, 说明本文提出的算法能够对多扩展目标进行良好的跟踪.

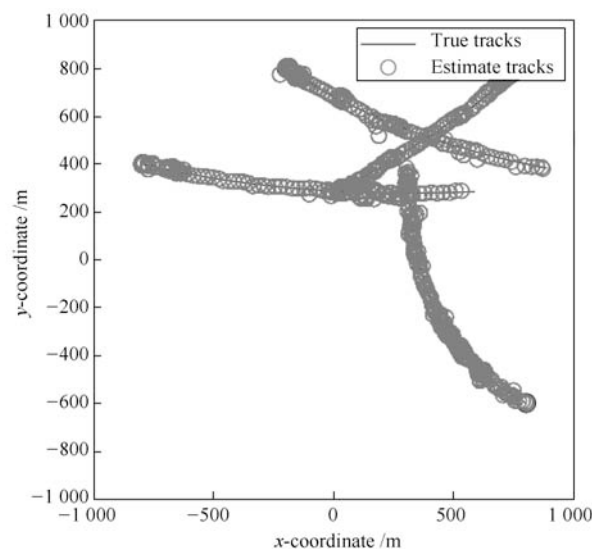


图 4 由 CBMeMber 滤波器得到的轨迹估计

Fig. 4 Track estimation by CBMeMber filter




图 5 由 GLMB 滤波算法得到状态估计

Fig. 5 The state estimation by GLMB filter

多扩展目标的个数估计如图 6 所示, 从图 6 中可以看出 GLMB 算法对多扩展目标个数的估计基本和真实个数吻合. 0 ~ 20s 目标的个数为 2 个, 在第 20s 后, 扩展目标 3 出生, 目标个数变为 3 个, 再到第 40s 后, 扩展目标 4 出现, 第 70s 时扩展目标 1 死亡, 再到第 80s 目标 3 死亡, 扩展目标个数最终变为 2 个. 而 CBMeMber 算法在对多扩展目标个数估计上存在较大的误差.

通过采用 OSPA 距离<sup>[39]</sup> 来评估本文给出的算法性能:

$$\bar{d}_p^{(c)}(X, \hat{X}) = \left\{ \frac{1}{n} \left[ \min_{\pi \in \Pi_n} \sum_{i=1}^m d^{(c)}(x_i, \hat{x}_{\pi(i)})^p + c^p(n-m) \right] \right\}^{\frac{1}{p}}$$

其中,  $X$  和  $\hat{X}$  分别为真实状态集和估计状态集, 个数分别为  $m$  和  $n$ , 且  $m \leq n, 1 < p < \infty$ ,  $d^{(c)}(x, \hat{x}) = \min\{c, d(x, \hat{x})\}$ ,  $c > 0$ ,  $\Pi_k$  表示  $1, 2, \dots, k$  所有各种排列组成的集合. 图 7 给出了



GLMB、LMB 和 CBMeMBe 算法 100 次蒙特卡洛 (Monte carlo, MC) 仿真后得到的 OSPA 结果.




图 6 多扩展目标个数估计对比  
Fig. 6 The cardinality estimates comparison for multiple extended targets




图 7 OSPA 距离 (100 MC runs)  
Fig. 7 OSPA distance (100 MC runs)

从图 7 OSPA 距离可以知道 GLMB 算法对多扩展目标的综合跟踪估计效果要优于 CBMeMBe 算法和 LMB 算法, OSPA loc 显示 CBMeMBe 算法也能较好估计出各目标的运动状态, 而现阶段研究的难点即对于多扩展目标的个数估计, 由 OSPA card 图可知 GLMB 算法对多扩展目标的个数估计更为精确, GLMB 算法能较好地实现在杂波条件下对多扩展目标个数的估计.

### 3.2 性能分析

本节对两种算法做性能比较, 用于测试算法的 64 位 Win10 系统 PC 机 CPU: Intel 2.50 GHz, Core i5-7200U, RAM: 4 GB. 针对上述实验仿真, 平均每步 CPU 耗时见下表所述:

表 1 算法性能分析

Table 1 Performance analysis of algorithms

算法	GLMB 算法 线性	CBMeMBe 算法 线性
时间 (秒/步)	1.37	0.05
目标个数估计准确率	97.8 %	84.6 %

通过上表我们知道在线性系统下广义标签多伯努利算法耗时远大于 CBMeMBe 算法. 分析原因, 这是因为 GLMB 为每个目标添加的标签, 致使计算复杂度逐渐上升, 所以 GLMB 滤波耗时要远大于 CBMeMBe 算法. 但是, 使用 GLMB 滤波算法, 在跟踪的过程中目标个数估计准确率高于 CBMeMBe 算法.

### 3.3 平行与交叉场景仿真实验

实验考虑多目标平行运动和交叉运动的场景, 目标数目时刻变化, 目标被检测到的概率为  $p_D = 0.98$ , 杂波为均匀分布, 杂波强度  $\lambda_c = 20$ , 杂波区域  $S = [-1000, 1000] \times [-1000, 1000] \text{ m}^2$ , 过程噪声  $Q_k = 0.5^2 \times B \times B^T$ . 扩展目标在 2 维平面做匀速直线 (CV) 运动, 检测时间为 100 s. 第 1 个扩展目标的存活时间为  $[1 \sim 80] \text{ s}$ , 第 2 个扩展目标的存活时间为  $[1 \sim 100] \text{ s}$ , 第 3 个扩展目标的存活时间为  $[1 \sim 90] \text{ s}$ , 第 4 个扩展目标的存活时间  $[1 \sim 100] \text{ s}$ .

4 个扩展目标的初始状态分别为:

$$\begin{aligned} x_1 &= [800 \text{ m}, -10 \text{ m/s}, 800 \text{ m}, -15 \text{ m/s}]^T \\ x_2 &= [800 \text{ m}, -10 \text{ m/s}, -800 \text{ m}, 15 \text{ m/s}]^T \\ x_3 &= [910 \text{ m}, -13 \text{ m/s}, 910 \text{ m}, -16 \text{ m/s}]^T \\ x_4 &= [910 \text{ m}, -13 \text{ m/s}, 750 \text{ m}, -16 \text{ m/s}]^T \end{aligned} \quad (61)$$

多扩展目标的运动场景真实轨迹如图 8 和图 9 所示, 其中两个扩展目标做相互平行的运动, 另两个目标做交叉运动, 圆形表示目标运动的起点, 三角形表示目标运动的终点.

图 10 和图 11 分别表示平行运行和交叉运动场景下目标的状态估计图, 不同颜色的轨迹代表不同扩展目标运动轨迹估计, 第一个图表示的是在  $x$  轴方向的跟踪轨迹, 第二个图表示在  $y$  轴方向上的跟踪轨迹. 由图可以看出估计点与真实轨迹基本吻合, 说明的本文提出的算法能够对交叉场景和平行场景下多扩展目标进行良好的跟踪.

交叉场景和平行场景下多扩展目标的个数估计如图 12 所示, 上图表示平行运动场景下的个数估计, 下图表示交叉运动场景下的扩展目标个数估计, 可见两种运动场景下目标个数估计都较为精确.




图 8 平行运动场景

Fig. 8 Parallel motion scenes




图 9 交叉运动场景

Fig. 9 Cross-motion scenes

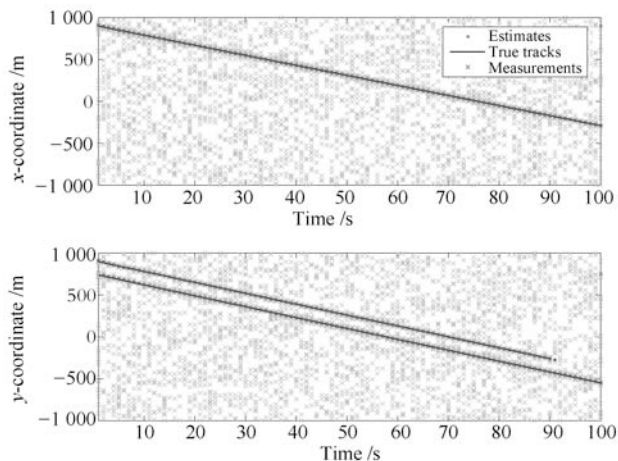


图 10 平行运动场景下状态估计

Fig. 10 State estimation in parallel motion scenes




图 11 交叉运动场景下状态估计

Fig. 11 State estimation in cross-motion scenarios

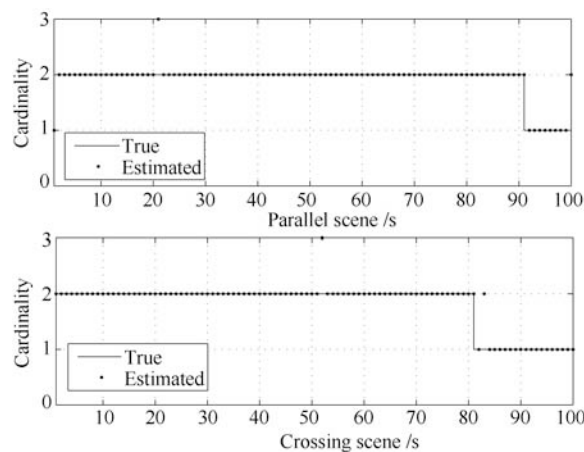


图 12 平行运动和交叉运动场景下的扩展目标个数估计

Fig. 12 Estimated number of extended targets in cross-motion and parallel motion scenarios




图 13 交叉运动和平行运动场景 OSPA 距离 (100 MCs)

Fig. 13 OSPA distance of cross-motion and parallel motion scenes (100 MCs)

图 13 给出了平行运动和交叉运动场景下本文

算法在 100 次蒙特卡洛 (Monte carlo, MC) 仿真后得到的 OSPA 结果. 从图中可以看出, 在 80 s 和 90 s 时候目标个数出现变化, OSPA 距离出现波动; 在 50 s 时, 交叉运动出现波动.

## 4 结论

针对杂波条件下多扩展目标的状态估计, 目标个数估计, 扩展目标形状估计问题, 本文提出一种基于 GLMB 滤波和 Gibbs 采样的有限混合模型多扩展目标形状采样学习与状态估计算法. 该算法结合 GLMB 滤波建立量测有限混合模型, 采用 Gibbs 采样算法估计高斯分布的均值协方差及各个高斯分布的权重, 然后利用 BIC 准则来判断高斯分布的拟合真实程度, 对扩展目标形状采用椭圆建模. 实验仿真结果表明该算法能够对多扩展目标进行有效的跟踪, GLMB 滤波算法对扩展目标个数的估计要明显优于 CBMeMBeR 算法. 但当检测范围内存在点目标, 群目标和扩展目标等多个混合目标时, 还需要做进一步研究.

## References

- Granstrom K, Lundquist C, Orguner U. Tracking rectangular and elliptical extended targets using laser measurements. In: Proceedings of the 14th International Conference on Information Fusion. Chicago, USA: IEEE, 2011. 1–8
- Granstrom K, Baum M. Extended Object Tracking: Introduction, Overview and Applications. *Journal of Advances in Information Fusion*, 2017, **12**(2): 139–174
- Bar-Shalom Y, Tse E. Tracking in a cluttered environment with probabilistic data association. *IEEE Transactions on Automatic Control*, 1975, **11**(9): 451–460
- Bar-Shalom Y. Tracking methods in a multi-target environment. *IEEE Transactions on Automatic Control*, 1978, **23**(6): 678–626
- Fortmann T, Bar-Shalom Y, Scheffe M. Sonar tracking of multiple targets using joint probabilistic data association. *IEEE Journal of Oceanic Engineering*, 1983, **8**(3): 173–184
- Reid D. An algorithm for tracking multiple targets. *IEEE Transactions on Automatic Control*, 1979, **24**(6): 843–854
- Blackman S. Multiple hypothesis tracking for multitarget tracking. *IEEE Transactions on Aerospace and Electronic Systems*, 2004, **11**(9): 5–18
- Koch W. Bayesian approach to extended object and cluster tracking using random matrices. *IEEE Transactions on Aerospace and Electronic Systems*, 2008, **44**(3): 1042–1059
- Feldmann M, Franken D, Koch W. Tracking of extended objects and group targets using random matrices. *IEEE Transactions on Signal Processing*, 2011, **59**(4): 1409–1420
- Baum M, Hanebeck U D. Random hypersurface models for extended object tracking. In: Proceedings of the 9th IEEE International Symposium on Signal Processing and Information Technology. Ajman, United Arab Emirates: IEEE, 2009. 178–183
- Gilholm K, Salmond D. Spatial distribution model for tracking extended objects. *IEEE Proceedings Radar, Sonar and Navigation*, 2005, **152**(5): 364–371
- Gilholm K, Godsill S, Maskell S, Salmond D. Poisson models for extended target and group tracking. In: Proceedings of Signal and Data Processing of Small Targets. San Diego, USA: SPIE, 2005. 230–241
- Mahler R. PHD filters for nonstandard targets, I: extended targets. In: Proceedings of the 12th International Conference on Information Fusion. Seattle, USA: IEEE, 2009. 915–921
- Granstrom K, Lundquist C, Orguner U. A Gaussian mixture PHD filter for extended target tracking. In: Proceedings of the 13th International Conference on Information Fusion, Edinburgh, UK: IEEE, 2010. 1–8
- Orguner U, Lundquist C, Granstrom K. Extended target tracking with a cardinalized probability hypothesis density filter. In: Proceedings of the 14th International Conference on Information Fusion. Chicago, USA: IEEE, 2011. 65–72
- Vo B T, Vo B N. Labeled random finite sets and multi-object conjugate priors. *IEEE Transactions on Signal Processing*, 2013, **61**(13): 3460–3475
- Beard M, Reuter S, Granstrom K, Vo B T, Vo B N and Scheel A. Multiple extended target tracking with labeled random finite sets. *IEEE Transactions on Signal Processing*, 2016, **64**(7): 1638–1653
- Lian Feng, Ma Dong-Dong, Yuan Xiang-Hui, Chen Wen, Han Chong-Zhao. CBMeMBeR filter for extended targets and its Gaussian mixture implementations. *Control and Decision*, 2015, **30**(04): 611–616  
(连峰, 马冬冬, 元向辉, 陈文, 韩崇昭. 扩展目标 CBMeMBeR 滤波器及其高斯混合实现. 控制与决策, 2015, **30**(04): 611–616)
- Baum M, Hanebeck U D. Shape tracking of extended objects and group targets with star-convex RHMs. In: Proceedings of the 14th International Conference on Information Fusion. Chicago, USA: IEEE, 2011. 1–8
- Aranstrom K, Orguner U. A PHD filter for tracking multiple extended targets using random matrices. *IEEE Transactions on Signal Processing*, 2012, **60**(11): 5657–5671
- Baum M, Hanebeck U D. Random Hypersurface Models for Extended Object Tracking. *IEEE International Symposium on Signal Processing and Information Technology*. Ajman, United Arab Emirates: IEEE, 2009. 178–183
- Li Peng, Yang Jin-Long, Ge Hong-Wei. Shape estimation of extended targets based on Gaussian surface feature matrix. *Journal of Opto-electronics Laser*, 2014, **25**(9): 1803–1811  
(李鹏, 杨金龙, 葛洪伟. 基于高斯曲面特征矩阵的扩展目标形状估计. 光电子激光, 2014, **25**(9): 1803–1811)
- Sun L, Lan J, Lix R. Extended target tracking using star-convex model with non-linear inequality constraints. In: Proceedings of the 31th Chinese Control Conference, Hefei, China: IEEE, 2012. 3869–3874
- Vo B N, Vo B T, Hoang H G. An efficient implementation of the generalized labeled multi-Bernoulli filter. *IEEE Transactions on Signal Processing*, 2017, **65**(8): 1975–1987
- Vo B N, Vo B T. An implementation of the multi-sensor generalized labeled multi-Bernoulli filter via Gibbs sampling. In: Proceedings of the 20th International Conference on Information Fusion, Xi'an, China, 2017. 1–8

- 26 Li Cui-Yun, Wang Yong, Ji Hong-Bing. Multiple extended-target tracking based on variational Bayesian cardinality-balanced multi-target multi-Bernoulli. *Control Theory & Applications*, 2015, **32**(02): 187–195  
(李翠芸, 王荣, 姬红兵. 基于变分贝叶斯势均衡多目标多伯努利滤波的多扩展目标跟踪算法. *控制理论与应用*, 2015, **32**(02): 187–195)
- 27 Liu Wei-Feng, Chai Zhong, Wen Cheng-Lin. Multi-measurement target tracking by using random sampling approach. *Acta Automatica Sinica*, 2013, **39**(2): 168–178  
(刘伟峰, 柴中, 文成林. 基于随机采样的多量测目标跟踪算法. *自动化学报*, 2013, **39**(02): 168–178)
- 28 Zhu Shu-Jun, Liu Wei-Feng, Cui Hai-Long. Multiple resolvable groups tracking by using GLMB filter. *Acta Automatica Sinica*, 2017, **43**(12): 2178–2189  
(朱书军, 刘伟峰, 崔海龙. 基于广义标签多伯努利滤波的可分辨群目标跟踪算法. *自动化学报*, 2017, **43**(12): 2178–2189)
- 29 Chen Y M, Liu W F, Wang X D. Multiple extended target tracking based on GLMB filter and gibbs sampler. In: *Proceedings of the 2017 International Conference on Control, Automation and Information Sciences (ICCAIS)*, Chiang Mai, Thailand, 2017. 26–31
- 30 Mahler R P S. *Statistical multisource-multitarget information fusion*. Boston: Artech House, USA, 2007.
- 31 Mahler R. Multitarget Bayes filtering via first-order multitarget moments. *IEEE Transactions on Aerospace and Electronic Systems*, 2003, **39**(4): 1152–1178
- 32 Mc Lachlan G, Peel D. *Finite mixture models*. New York, John Wiley Sons, 2000.
- 33 Vo B N, Vo B T, Phung D. Labeled random finite sets and the Bayes multi-target tracking filter. *IEEE Transactions on Signal Processing*, 2014, **62**(24): 6554–6567
- 34 Diebolt J, Robert P. Estimation of finite mixture distributions through Bayesian sampling. *Journal of the Royal Statistical Society* 1994, **56**(2): 363–375
- 35 Vo B N, Vo B T, Phung D. Labeled random finite sets and the bayes multi-target tracking filter. *IEEE Transactions on Signal Processing*, 2014, **62**(24): 6554–6567
- 36 Geman S, Geman D. Stochastic relaxation, Gibbs distributions, and the Bayesian restoration of image. *IEEE Transaction on Pattern Analysis and Machine Intelligence*, 1984, **6**(4): 721–741
- 37 Liu W F, Cui H L, Wen C L. A time-varying clutter intensity estimation algorithm by using gibbs sampler and BIC. In: *Proceedings of the 19th International Conference on Information Fusion*. Germany, IEEE, 2016. 1546–1553
- 38 Vo B T, Vo B N, and Cantoni A. The cardinality balanced multi-target multi-Bernoulli filter and its implementations. *IEEE Transaction on Signal Processing*, **57**(2): 409–423

- 39 Schuhmacher D, Vo B T, Vo B N. A consistent metric for performance evaluation of multi-object filters. *IEEE Transactions on Signal Processing*, 2008, **56**(8): 3447–3457



**陈一梅** 杭州电子科技大学自动化学院系统科学与控制工程研究所硕士研究生。主要研究方向为目标跟踪, 信息融合。

E-mail: chenym245600@163.com

(**CHEN Yi-Mei** Master student at the Institute of Systems Science and Control Engineering, School of Automation, Hangzhou Dianzi University.

Her research interest covers target tracking and information fusion.)



**刘伟峰** 杭州电子科技大学副教授。主要研究方向为目标跟踪, 不确定信息处理, 模式识别。本文通信作者。

E-mail: liuwf@hdu.edu.cn

(**LIU Wei-Feng** Associate professor at Hangzhou Dianzi University. His research interest covers target tracking, uncertain information processing, and pattern recognition. Corresponding author of this paper.)



**孔明鑫** 杭州电子科技大学自动化学院系统科学与控制工程研究所硕士研究生。主要研究方向为深度学习, 目标识别。

E-mail: 171060021@hdu.edu.cn

(**KONG Ming-Xin** Master student at the Institute of Systems Science and Control Engineering, School of Automation, Hangzhou Dianzi University.

Her research interest covers deep learning and target identification.)



**张桂林** 中国电子科技集团公司第二十八研究所研究员。主要研究方向为为目标跟踪, 不确定信息处理, 模式识别。

E-mail: 1917907284@qq.com

(**ZHANG Gui-Lin** Professor at the 28th research institute of China electronics technology group corporation. His research interest covers tar-

get tracking, uncertain information processing, and pattern recognition.)