

基于改进 K -means++ 聚类的多扩展目标跟踪算法

俞皓芳¹, 孙力帆^{1,2*}, 付主木¹

(1. 河南科技大学 信息工程学院, 河南 洛阳 471203; 2. 电子科技大学 通信与信息工程学院, 成都 611731)

(* 通信作者电子邮箱 lifan_sun@126.com)

摘 要: 针对多扩展目标跟踪过程中量测集划分准确度和计算量大的问题, 提出一种基于改进 K -means++ 聚类划分的高斯混合假设密度强度多扩展目标跟踪算法。首先 根据下一时刻目标可能变化的情况缩小 K 值的遍历范围; 其次 利用目标预测状态选择初始聚类中心点, 为正确划分量测集提供依据, 从而提高聚类算法的精度; 最后 将所提改进 K -means++ 聚类划分方法应用到高斯混合概率假设滤波器中, 联合估计多个目标的个数和状态。仿真实验结果表明: 与基于距离划分和基于 K -means++ 的多扩展目标跟踪算法相比, 该算法在平均跟踪时间上分别减小了 59.16% 和 53.25%, 同时其最优子模式指派度量 (OSPA) 远小于以上两种算法。综上, 该算法能在大幅度降低计算复杂度的同时取得比现有量测集划分方法更为优异的跟踪性能。

关键词: 多目标跟踪; 扩展目标; 概率假设密度; 高斯混合; K -means++ 聚类

中图分类号: TP301.6 **文献标志码:** A

Multi-extended target tracking algorithm based on improved K -means++ clustering

YU Haofang¹, SUN Lifan^{1,2*}, FU Zhumu¹

(1. Information Engineering College, Henan University of Science and Technology, Luoyang Henan 471023, China;

2. School of Communication and Information Engineering, University of Electronic Science and Technology of China, Chengdu Sichuan 611731, China)

Abstract: In order to solve the problem of low partition accuracy of measurement set and high computational complexity, a Gaussian-mixture hypothesis density intensity multi-extended target tracking algorithm based on improved K -means++ clustering algorithm was proposed. Firstly, the traversal range of K value was narrowed according to the situations that the targets may change at the next moment. Secondly, the predicted states of targets were used to select the initial clustering centers, providing a basis for the correct partition of measurement set to improve the accuracy of clustering algorithm. Finally, the proposed improved K -means++ clustering algorithm was applied to the Gaussian-mixture probability hypothesis filter to jointly estimate the number and states of multiple targets. The simulation results show that the average tracking time of the proposed algorithm is reduced by 59.16% and 53.25% respectively, compared with that of multi-extended target tracking algorithms based on distance partition and K -means++. Meanwhile, the Optimal Sub-Pattern Assignment (OSPA) of the proposed algorithm is much lower than that of above two algorithms. In summary, the algorithm can greatly reduce the computational complexity and achieve better tracking performance than existing measurement set partition methods.

Key words: multi-target tracking; extended target; probability hypothesis density; Gaussian mixture; K -means++ clustering

0 引言

多目标跟踪技术是信息融合方法的重要组成部分, 被广泛用于防空预警、沿海舰船监视、视频监控、智能交通管理系统、移动机器人定位与导航和定位等军事和民用领域。多目标跟踪的本质是使用含杂波的传感器量测数据集持续地对多个动态目标的运动状态和目标个数进行估计^[1], 其准确度直接影响到多目标的跟踪效果。传统多目标跟踪算法^[2-3]均基于“点目标”假设 (即将距离传感器较远的目标建模为点目标, 并假设其每一时刻最多只能生成一个量测), 通常利用量

测与目标点源之间的某种数据关联将量测数据分配给某个目标, 但是点源数量与位置的不确定性影响数据关联的准确性, 从而难以应对目标个数未知、杂波密集等环境, 为此, 在多点目标跟踪算法中引入随机有限集 (Random Finite Set, RFS) 概念^[4], 该方法不仅能避免量测和目标之间的数据关联, 而且能对实际场景中多目标跟踪涉及到的目标出现、分裂、消失以及传感器漏检和虚警杂波等现象进行严格的数学描述。Mahler^[5]提出了一种概率假设密度 (Probability Hypothesis Density, PHD) 滤波器, 它是后验概率密度的一阶矩, 也称为定义在单目标状态空间上的强度函数。PHD 滤波器不但能够

收稿日期: 2019-06-21; 修回日期: 2019-09-03; 录用日期: 2019-09-19。

基金项目: 国家“十三五”装备预研共用技术和领域基金资助项目 (61403120207); 国家国防基础研究计划项目 (JCKY2018419C001); 航空科学基金资助项目 (20185142003); 国家自然科学基金资助项目 (U1504619, 61671139); 河南省科技攻关计划项目 (182102110397, 192102210064, 172102310636); 河南省高校科技创新团队支持计划项目 (18IRTSTHN011)。

作者简介: 俞皓芳 (1995—), 女, 浙江诸暨人, 硕士研究生, 主要研究方向: 多目标跟踪、扩展目标跟踪; 孙力帆 (1982—), 男, 河南洛阳人, 副教授, 博士, 主要研究方向: 多扩展目标跟踪、多传感器信息融合; 付主木 (1974—), 男, 湖北仙桃人, 教授, 博士, 主要研究方向: 不确定信息处理、机器视觉。

实时地迭代更新后验概率强度,还具有无需数据关联、计算量低、估计精度高、易于实现等优势。

近年来,随着高分辨率传感器的飞速发展以及战争环境的复杂多变性,当目标较大或者目标距离高分辨率传感器较近时,目标回波可能占据传感器的多个分辨单元,导致同一目标每一时刻产生多个量测。为更贴近实际跟踪场景,此类目标通常称为多扩展目标^[1]。不同于传统点目标,扩展目标跟踪还需要定义多个量测产生过程,为其空间扩展建模或对量测集进行有效的划分^[6-8],以能合理而又准确描述目标状态与测量值之间的关系,故而无法直接使用 PHD 滤波器实现多扩展目标状态和个数的精确估计。文献[9-12]中提出基于 PHD 滤波器框架的多扩展目标跟踪算法,以扩展目标 PHD (Extended Target PHD, ET-PHD) 滤波器、扩展目标 CPHD (Extended Target Cardinalized PHD, ET-CPHD) 滤波器、扩展目标高斯混合 PHD (Extended Target Gaussian Mixture PHD, ET-GM-PHD) 滤波器、扩展目标高斯混合 CPHD (Extended Target Gaussian Mixture Cardinalized PHD, ET-GM-CPHD) 滤波器为代表的滤波器被广泛应用于多扩展目标跟踪中。

上述滤波器均假定量测个数服从泊松分布且随机散布在目标参考点(可以是质心或任何其他点,取决于扩展目标的范围和形状)周围空间上^[3],每一时刻观测到的量测是一组点,而不是几何结构的整体。故在 PHD 滤波器框架下,现有众多算法需要完全划分量测集,目的是尽可能将源自同一目标的量测划分在同一子集中,其划分的合理性和准确性将直接影响后续跟踪算法中目标状态和个数估计的联合性能。传统量测集划分方法充分考虑所有可能的划分,故每一时刻的划分次数将随着目标数增多而变得十分庞大,仅适合扩展目标数量较少的跟踪场景。Granström 等^[13]提出一种距离划分方法以减小计算负担,即根据经验缩小距离阈值范围,但是其划分次数仍然会随着量测个数增加而大幅度增加,且在目标距离相近环境下目标数估计不准确。此外,该方法在 PHD 滤波更新过程中,会出现因不合理的量测集划分而额外带来的计算负担,特别是在杂波密度较大时,无法取得较为理想的跟踪效果。 K -means 聚类算法能将量测集划分为 K 个子集,由于多扩展目标跟踪过程中目标数未知且时变,故通常设置 K 值区间为 $[1, |Z_k|]$,并通过遍历 K 值得到不同的量测集划分结果,但是随着量测个数增加, K 值范围将扩大,导致量测集划分次数十分庞大,造成极大的计算负担,同时聚集初始点选取受到随机性影响,使得量测集划分非常不稳定,从而导致目标数估计存在较大误差^[11,14]。文献[15]对聚类初始点的选取进行了改进并提出了 K -means++ 聚类算法,该算法虽然提高了量测集划分的稳定性,但是没有明确讨论 K 的取值范围,而 K 的取值直接影响划分量测集的速度。此外,相比于距离度量所进行的量测集划分,其目标状态和个数估计精度未必得以提升,而且也存在目标相近时量测集划分不准确的问题。

鉴于上述问题,本文提出一种基于改进 K -means++ 聚类算法的 ET-GM-PHD 滤波器,旨在准确划分量测集以提升多扩展目标跟踪性能。该方法设置 K 的上下限,首先利用预测状态选择初始中心点,然后计算每个量测到初始中心点的距离并遍历 K 值,从而最终得到量测集的所有划分。实验结果表明,相比于距离划分和 K -means++ 划分方法,该方法能提

高聚类算法的稳定性,大幅度降低计算复杂度,同时保证多扩展目标的跟踪效果。

1 多扩展目标系统模型

1.1 多扩展目标动态演化模型

假设某一跟踪场景中存在 $N_{x,k}$ 个扩展目标,利用随机有限集 $X_k = \{x_k^{(i)}\}_{i=1}^{N_{x,k}}$ 来描述当前时刻的多扩展目标状态集合,其中: $N_{x,k}$ 表示状态集合中的扩展目标个数, $x_k^{(i)}$ 表示当前时刻的第 i 个扩展目标的状态。在 k 时刻,单个扩展目标的状态向量可由 $x_k = [m_k^T (x_k^*)^T]^T$ 表示,其中: $m_k^T = [\hat{x}_k, \hat{y}_k]^T$ 为扩展目标的位置向量; $(x_k^*)^T$ 为可选向量,例如表示速度分量等。 x_k 中不含任何关于目标大小尺寸和形态信息,即不对目标的空间扩展进行估计。

若每个目标状态的动态演化相互独立,且服从线性高斯运动模型,则状态集合 X_k 中每个目标的动态演化模型为:

$$x_{k+1}^{(i)} = F_k x_k^{(i)} + w_k^{(i)}; i = 1, 2, \dots, N_{x,k} \quad (1)$$

其中: F_k 是当前时刻的状态转移矩阵; $w_k^{(i)}$ 是高斯白噪声,其协方差为 $Q_k^{(i)}$ 。

1.2 多扩展目标量测模型

在 k 时刻,传感器所观测到的量测数据被建模为随机有限集,可用 $Z_k = \{z_k^{(i)}\}_{i=1}^{N_{z,k}}$ 表示,其中 $N_{z,k}$ 表示 k 时刻的量测个数, $z_k^{(i)}$ 表示第 i 个量测,用二维位置向量描述。需要注意的是,每一个时刻得到的量测集同时包含由目标和杂波产生的量测,故 $z_k^{(i)}$ 可能由目标产生,也可能由杂波产生。

假设第 i 个目标 $x_k^{(i)}$ 一共产生 $N_{m,k}^{(i)}$ 个量测,其中 $N_{m,k}^{(i)}$ 服从参数为 $\gamma(x_k^{(i)})$ 的泊松分布,则在 k 时刻 $x_k^{(i)}$ 产生至少一个量测的概率为 $1 - e^{-\gamma(x_k^{(i)})}$ 。若 $x_k^{(i)}$ 被检测到的概率为 $p_D(x_k^{(i)})$,则目标 $x_k^{(i)}$ 产生至少一个量测并被检测到的概率可用有效检测概率为 $(1 - e^{-\gamma(x_k^{(i)})}) p_D(x_k^{(i)})$ 。同时,每一时刻杂波产生的量测均匀分布在监控区域, N_k^c 表示 k 时刻由杂波产生的量测个数,服从泊松分布。 β_{FA} 表示每次扫描中单位检测体积内杂波产生量测个数的期望。如果检测空间的体积为 V_s ,那么每次扫描得到的杂波量测个数 N_k^c 为 $\beta_{FA} V_s$ 。

假设跟踪场景中目标和杂波产生的量测相互独立,且第 i 个目标状态的量测 $z_k^{(i)}$ 与目标状态 $x_k^{(i)}$ 相关并服从线性高斯模型:

$$z_k^{(i)} = H_k x_k^{(i)} + e_k^{(i)} \quad (2)$$

其中: H_k 是 $N_z \times N_x$ 维量测矩阵; $e_k^{(i)}$ 是高斯白噪声,其协方差为 $R_k^{(i)}$ 。

2 多扩展目标的量测集划分问题

在 ET-GM-PHD 框架中,多扩展目标的量测集划分是必不可少的。传统点目标每一时刻最多产生一个量测,但扩展目标每一时刻会产生多个散的点量测,且跟踪场景中目标状态与量测之间的关联是未知的,这增加了对多扩展目标进行量测集划分的难度,并且量测集划分的准确与否将很大程度上决定 ET-GM-PHD 滤波器能否准确实现多目标跟踪。针对扩展目标,由于目标可能产生不止一个量测,通常将当前时刻得到的量测集划分为不同子集,并使其尽可能包含由来自于同一目标的量测,其本质上通过使用某种度量将同属一个目

标的量测划分到一个量测子集中。传统的量测集划分原则是列举所有可能的划分,假设 k 时刻传感器观测到含有杂波的量测集包含三个相互独立的量测 $Z_k = \{z_k^{(1)} z_k^{(2)} z_k^{(3)}\}$,那么共有以下 5 种划分方式:

$$\begin{aligned} p_1: W_1^1 &= \{z_k^{(1)} z_k^{(2)} z_k^{(3)}\} \\ p_2: W_1^2 &= \{z_k^{(1)} z_k^{(2)}\}, W_2^2 = \{z_k^{(3)}\} \\ p_3: W_1^3 &= \{z_k^{(1)} z_k^{(3)}\}, W_2^3 = \{z_k^{(2)}\} \\ p_4: W_1^4 &= \{z_k^{(2)} z_k^{(3)}\}, W_2^4 = \{z_k^{(1)}\} \\ p_5: W_1^5 &= \{z_k^{(1)}\}, W_2^5 = \{z_k^{(2)}\}, W_3^5 = \{z_k^{(3)}\} \end{aligned}$$

其中 W_j^i 表示第 i 种可能划分 p_i 里的第 j 个划分子集。显然,随着量测集中量测个数的增加,计算量将呈指数增长。针对这一问题,Granström 等^[13]提出了一种基于距离阈值的距离划分方法,对距离阈值设置上下限,但是存在目标相近时目标数估计不准确的问题,因此,文献[11]对该方法进行了改进,即根据每个子集中目标个数的极大似然估计结果判断是否对该子集二次划分,同时将重新划分后得到的结果加入原有的划分中。虽然这样做可以解决目标相近时量测集划分不准确的问题,但是若想获得良好的跟踪效果仍需以较大的计算量为代价。

除了距离划分方法,聚类算法也可用于量测集划分。以 K-means 聚类算法为例,为了得到多个可能的划分,一般使量测子集数 K 在 $[1, |Z_k|]$ 区间内遍历,其中 $|Z_k|$ 表示当前时刻量测集中量测的个数;然而,使用 K-means 聚类算法进行量测集划分所取得的跟踪性能不稳定,其原因在于 K-means 聚类算法中初始中心点采用随机选取。针对上述问题,文献[15]中提出了 K-means++ 算法,根据选择概率来确定初始中心点。虽然该方法在一定程度提高了聚类结果的稳定性;但是易受到杂波干扰,以致后续的量测集划分准确度不高,从而无法获得较为优异的多扩展目标跟踪性能。

3 改进的 ET-GM-PHD 滤波器

3.1 改进 K-means++ 聚类算法的多扩展目标量测集划分

由于每一时刻的扩展目标个数 K 未知,其取值范围通常为 $[K_L, K_U]$,上下限取值一般为 $K_L = 1, K_U = |Z_k|$;然而在此区间内遍历 K 值,每一时刻得到的量测划分集合会随着量测个数的增多而呈指数增长,从而导致计算量大幅度增加。

因此,本文考虑下一时刻目标可能出现的情况缩小 K 值范围,具体分析如下:若 $k-1$ 时刻已存在目标 x_{k-1} ,则在 k 时刻,该目标可能继续存在,或者衍生出新的目标 $x_{\text{beta } k-1}$;若 $k-1$ 时刻不存在的目标 $x_{\text{gam } k}$,则它有可能在 k 时刻出现。

综上所述,假设 $k-1$ 时刻估计得到的目标个数为 J_{k-1} , $J_{\text{beta } k}$ 表示单个目标可能衍生的目标个数, $J_{\text{gam } k}$ 表示 k 时刻可能的新目标个数,若令 $K_L = J_{k-1}$,那么 $K_U = J_{k-1} + J_{\text{beta } k} \times J_{k-1} + J_{\text{gam } k}$ 相应地

$$J_{k-1} \leq K \leq J_{k-1} + J_{\text{beta } k} \times J_{k-1} + J_{\text{gam } k}$$

其中 $J_{\text{beta } k} \sim J_{\text{gam } k}$ 通常未知,一般使用 $k-1$ 时刻的目标个数 J_{k-1} 所代替。

由于 K-means++ 算法中第一个初始中心点是随机选取,即便余下的初始中心点依据一定的概率选择,也会因为量测集的不准确划分导致目标跟踪性能不稳定。考虑到预测状态及其个数在一定程度上能为正确划分量测集提供依据,本文

对聚类初始中心点选取方式进行改进,即根据预测状态选择其中 J_{k-1} 个初始中心点,以增加量测集划分的可信度,从而大幅度提高聚类效果的稳定性,其划分流程如图 1 所示。

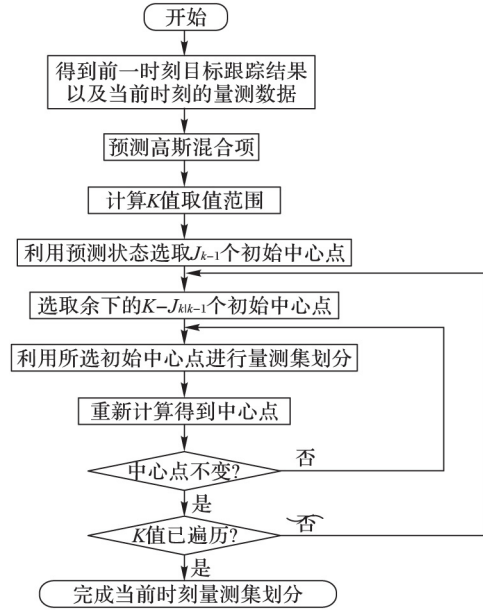


图 1 量测集划分流程

Fig. 1 Flowchart of measurement set partition

假设 k 时刻的量测集为 $Z_k = \{z_k^{(i)} | i = 1, 2, \dots, |Z_k|\}$,

本文提出的改进 K-means++ 聚类算法具体实施步骤如下。

1) 选择距离每个预测状态 $x_{k-1}^i \in X_{k-1}$ 最近的量测作为前 J_{k-1} 个初始中心点,其中 X_{k-1} 表示预测状态集。

2) 余下的 $K - J_{k-1}$ 个初始中心点的选择方式如下:选择 $z_k^{(i)}$ 作为下一个初始中心点,满足选择概率 $(D(z_k^{(i)})^2) / (\sum_{z_k \in Z_k} D(z_k)^2)$,其中 $D(z_k)$ 表示量测 $z_k^{(i)}$ 与最近已选择中心点的距离。

3) 重复步骤 2),直到完成 K 个初始中心点的选择,得到初始中心点集合 $C = \{c_i\}_{i=1}^K$ 。

4) 计算每个量测到初始中心点集合 C 内每个初始中心点的距离,依据最小距离对量测集进行划分。

5) 重新计算每个聚类的均值并作为新的中心点 $c_i = \frac{1}{|C_i|} \sum_{x \in C_i} x$ 。

6) 重复步骤 4)、5),直到中心点几乎不变。

7) 遍历 K 值,最终得到不同的量测集划分结果。

3.2 本文算法流程

文献[1]中针对多扩展目标跟踪提出了 ET-GM-PHD 滤波器。对比标准的 GM-PHD 滤波器^[13],ET-GM-PHD 的预测方程、删减合并高斯混合项以及状态提取步骤与 GM-PHD 滤波器一致,最大的不同在于量测更新部分,其主要原因是扩展目标不同于传统点目标,每一时刻同一目标至少产生多个量测的性质决定 ET-GM-PHD 的量测更新步骤不再是简单地将所有量测逐一进行高斯混合项更新。本文针对 K-means++ 聚类算法随机选取初始中心点导致聚类精度不高、跟踪效果不理想的问题,考虑目标个数在下一时刻的可能动态变化以及预测状态为准确划分量测集提供的可靠信息,提出了一种基于改进 K-means++ 量测集划分的 ET-GM-PHD 滤波器算

法。

假设扩展目标的动态演化和量测生成机制均为线性高斯模型,如式(1)和(2)所示。由于扩展目标的存活概率、传感器的检测概率和目标状态相互独立,预测强度函数和后验强度函数均为高斯混合形式,则 ET-GM-PHD 滤波器的预测方程描述如下:

$$D_{k|k-1}(x) = \sum_{j=1}^{J_{k|k-1}} \omega_{k|k-1}^{(j)} N(x; m_{k|k-1}^{(j)}, P_{k|k-1}^{(j)}) \quad (3)$$

其中: $D_{k|k-1}(x)$ 为预测强度函数; $J_{k|k-1}$ 为预测强度函数的高斯项个数; $\omega_{k|k-1}^{(j)}$ 为第 j 个预测高斯项的权重; $m_{k|k-1}^{(j)}$ 和 $P_{k|k-1}^{(j)}$ 分别是第 j 个高斯项的均值和协方差。

由 ET-PHD 滤波器的更新方程推导得到 ET-GM-PHD 滤波器更新如下:

$$D_k(x) = D_k^{ND}(x) + \sum_{P \subseteq Z_k} \sum_{W \in P} D_{k|k}^D(x, W) \quad (4)$$

其中: $D_k^{ND}(x)$ 处理传感器未检测到扩展目标的情况,具体表示如下:

$$D_k^{ND}(x) = \sum_{j=1}^{J_{k|k-1}} \omega_{k|k}^{(j)} N(x; m_{k|k}^{(j)}, P_{k|k}^{(j)}) \quad (5)$$

其中:

$$\omega_{k|k}^{(j)} = (1 - (1 - e^{-\gamma}) p_D) \omega_{k|k-1}^{(j)} \quad (6)$$

$$m_{k|k}^{(j)} = m_{k|k-1}^{(j)} \quad (7)$$

$$P_{k|k}^{(j)} = P_{k|k-1}^{(j)} \quad (8)$$

其中: γ 和 p_D 为常数,即把与预测状态相关的量测个数的期望 $\gamma(m_{k|k-1}^{(j)})$ 和目标检测概率 $p_D(m_{k|k-1}^{(j)})$ 分别设为常数, $\gamma(m_{k|k-1}^{(j)}) = \gamma p_D(m_{k|k-1}^{(j)}) = p_D$, 那么式(4)中 $\sum_{P \subseteq Z_k} \sum_{W \in P} D_{k|k}^D(x, W)$ 用来处理扩展目标被检测到的情况,其中 $P \subseteq Z_k$ 表示对量测集 Z_k 进行的 P 次划分, $W \in P$ 表示每个划分中的子集单元 W , $D_{k|k}^D(x, W)$ 表示对应子集单元 W 检测到目标的强度函数,具体表示如下:

$$D_{k|k}^D(x, W) = \sum_{j=1}^{J_{k|k-1}} \omega_{k|k}^{(j)} N(x; m_{k|k}^{(j)}, P_{k|k}^{(j)}) \quad (9)$$

其中:

$$\omega_{k|k}^{(j)} = \omega_P \frac{\Gamma^{(j)} p_D}{d_W} \Phi_W^{(j)} \omega_{k|k-1}^{(j)} \quad (10)$$

$$\omega_P = \left(\prod_{W \in P} d_W \right) / \left(\sum_{P' \subseteq Z_k} \prod_{W \in P'} d_W \right) \quad (11)$$

$$d_W = \delta_{|W|, 1} + \sum_{l=1}^{J_{k|k-1}} \Gamma^{(l)} p_D \Phi_W^{(l)} \omega_{k|k-1}^{(l)} \quad (12)$$

$$\Gamma^{(j)} = e^{-\gamma}(\gamma)^{|W|} \quad (13)$$

$$\Phi_W^{(j)} = \prod_{z_k \in W} \frac{\varphi_{z_k}(x)}{\lambda_k c_k(z_k)} \quad (14)$$

$$\varphi_{z_k}(x) = N(z_k | H_K m_{k|k-1}^{(j)}, R_K + H_K P_{k|k-1}^{(j)} H_K^T) \quad (15)$$

其中: ω_P 表示对应划分 P 的权重; $\delta_{|W|, 1}$ 表示克罗内克函数; $|W|$ 表示单元 W 中量测的个数; $c_k(z_k)$ 表示由杂波产生量测的分布函数,一般假设其服从均匀分布; λ_k 表示由杂波产生量测个数的期望,通常设为常数 λ 。

滤波算法中其余的高斯分量均值和协方差更新可直接在卡尔曼滤波框架内进行。需要注意的是,所有划分结果均由本文提出的改进 K -means++ 量测划分方法得到,另外本文不同于传统 GM-PHD 滤波器的更新步,该算法需用所有分区中

每个子集单元 W 更新每个高斯分量,具体计算如下:

$$m_{k|k}^{(j)} = m_{k|k-1}^{(j)} + K_k^{(j)} ([z_1 \ z_2 \ \cdots \ z_{|W|}]^T - H_K m_{k|k-1}^{(j)}) \quad (16)$$

$$P_{k|k}^{(j)} = (I - K_k^{(j)} H_K) P_{k|k-1}^{(j)} \quad (17)$$

其中:

$$K_k^{(j)} = P_{k|k-1}^{(j)} H_K^T (R_K + H_K P_{k|k-1}^{(j)} H_K^T)^{-1} \quad (18)$$

$$H_K = \underbrace{[H_k^T \ H_k^T \ \cdots \ H_k^T]}_{|W| \text{ times}}^T \quad (19)$$

$$R_K = \text{blkdiag}(\underbrace{R_k \ R_k \ \cdots \ R_k}_{|W| \text{ times}}) \quad (20)$$

其中: $K_k^{(j)}$ 表示卡尔曼增益矩阵, H_K 、 R_K 分别表示扩维后的量测矩阵和噪声协方差矩阵, blkdiag 表示分块对称矩阵函数。

综上,本文提出的算法流程归纳如下:

- 1) 已知 $k-1$ 时刻的目标强度函数 $D_{k-1|k-1}(x)$, 计算得到 k 时刻的预测目标强度函数 $D_{k|k-1}(x)$;
- 2) 利用 $k-1$ 时刻的目标个数 $J_{k-1|k-1}$ 计算得到 K 值取值区间 $[K_L, K_U]$, 其中包含 n_K 个不同的 K 值;
- 3) 对于任意整数 $k_i \in [K_L, K_U]$, 利用预测目标强度函数中高斯混合项的均值得到改进 K -means++ 量测集划分方法的初始中心点集 $C = \{c_1, c_2, \dots, c_{k_i}\}$;
- 4) 利用改进 K -means++ 量测集划分方法将 k 时刻的量测集 Z_k 划分为 k_i 个子集;
- 5) 重复步骤 3)、4), 依次遍历 K 值, 得到 n_K 种不同的划分结果;
- 6) 将量测集的所有划分结果代入式(4)、(5)、(9) 对预测目标强度函数进行更新, 得到更新后的目标强度函数 $D_{k|k}(x)$;
- 7) 对更新后的目标强度函数的高斯混合项进行删除合并、状态提取, 得到目标状态和个数估计。

4 仿真实验对比与性能评估

为验证本文提出的基于改进 K -means++ 量测集划分的多扩展目标跟踪算法的有效性, 考虑在杂波环境下跟踪多个扩展目标的仿真实验场景。假设有 4 个扩展目标在二维笛卡尔积平面内沿着图 2 的轨迹运动, 其运动状态向量为 x 方向和 y 方向上的位置分量 $X_k = [x_k \ y_k \ v_k^x \ v_k^y]^T$, x_k 和 y_k 分别为目标在 x 方向和 y 方向上的位置分量, v_k^x 和 v_k^y 分别为 x 方向和 y 方向上的速度分量。目标的动态模型和量测模型具有如下形式:

$$F_k = \begin{bmatrix} 1 & 0 & T & 0 \\ 0 & 1 & 0 & T \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 1 \end{bmatrix} Q_k = \sigma_w^2 I_2$$

$$H_k = \begin{bmatrix} 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \end{bmatrix} R_k = \sigma_e^2 I_2$$

其中 $\sigma_w = 2 \text{ m/s}^2$, $\sigma_e = 20 \text{ m}$ 。

整个运动过程仿真实验时间 $t = 100 \text{ s}$, 采样周期为 1 s , 其中在 $k = 66$ 时新生出另外两个目标。传感器观测到的量测可表示为 $z_k^{(j)} = [x_k^{(j)} \ y_k^{(j)}]$ 。目标的存活概率设为 $p_s = 0.99$, 检测概率设为 $p_D = 0.99$ 。每一时刻目标产生量测个数的参数设为 $\gamma^{(i)} = 10, \forall i$, 杂波量测个数也服从参数为 10 的泊松分布, 同时杂波量测均匀分布在量测空间中。本文多扩展目标跟踪仿真实验所设置的监视区域为 $[-1000; 1000] \text{ m} \times [-1000;$

1000] m, 新生目标的强度函数为:

$$D_b(x) = 0.1N(x; m_b^{(1)} | P_b) + 0.1N(x; m_b^{(2)} | P_b);$$

$$m_b^{(1)} = [250 \ 250 \ 0 \ 0]^T,$$

$$m_b^{(2)} = [-250 \ -250 \ 0 \ 0]^T,$$

$$P_b = \text{diag} [100 \ 100 \ 25 \ 25]$$




图2 真实目标运动轨迹及观测

Fig. 2 Trajectories and measurements of true objects

在仿真实验中设定 $p = 1$, $c = 200$, p 阶 OSPA 距离

$\bar{d}_p^{(c)}(X, Y)$ 计算如下:

$$\bar{d}_p^{(c)}(X, Y) = \left(\frac{1}{n} \left(\min_{\pi \in \Pi_n} \sum_{i=1}^m d^{(c)}(x_i, y_{\pi(i)})^p + c^p(n-m) \right) \right)^{1/p}$$

其中 $X = \{x_i\}_{i=1}^m$ 为目标状态的真实值, $Y = \{y_i\}_{i=1}^n$ 为目标状态的估计值。

仿真使用计算机的 CPU 为 Intel Core i3-2130、内存为 4 GB, 仿真实验使用的量测数据由 Matlab 代码产生。为验证所提方法的有效性, 在以上场景中与现有方法进行跟踪性能对比。

1) MK-means++: 本文提出基于改进 K-means++ 量测划分的多扩展目标跟踪算法。

2) K-means++: 基于 K-means++ 量测划分的多扩展目标跟踪算法。

3) DP(Distance Partition): 基于距离度量量测划分的多扩展目标跟踪算法。

图3~4 是在相同运行环境下, 分别采用本文算法、K-means++ 聚类算法和基于距离度量的量测划分算法得到的 X、Y 轴目标状态跟踪结果。对比图3(a)、图3(c)、图4(a)和图4(c), 可以粗略地判断本文算法与距离划分算法的多扩展目标跟踪效果接近。图3(b)和图4(b)显示 K-means++ 聚类算法的跟踪效果十分不理想, 尤其当目标数增加时, 不能完全跟踪所有目标, 其主要原因是 K-means++ 聚类算法随机选取初始中心点, 导致量测集划分不合理, 直接影响多扩展目标跟踪效果。




图3 三种量测集划分方法的 X 轴目标状态估计结果

Fig. 3 X-axis target state estimation results of three measurement set partition methods




图4 三种量测集划分方法的 Y 轴目标状态估计结果

Fig. 4 Y-axis target state estimation results of three measurement set partition methods

图5 对比了本文算法、K-means++ 聚类算法和距离划分算法下的目标势估计结果, 本文算法的聚类结果远比 K-means++ 聚类算法稳定, 并且能准确地估计真实目标个

数, 其目标势估计结果甚至优于距离划分方法, 其原因在于本文算法利用目标的预测状态选择初始中心点的选择, 为量测集划分提供了可靠的划分依据, 而准确的量测集划分结果提

高了后续的目标数估计准确度。

图6是三种算法的OSPA距离对比。图5可以更加清晰地看出,相比于K-means++聚类算法,本文算法能大幅度改善目标的跟踪效果,并且不论从目标个数估计还是目标状态估计的角度,本文算法皆具有比距离划分算法较好的效果,其原因是本文算法利用预测状态提高聚类精度,大幅度提高了目标状态和个数估计的准确性。




图5 三种量测集划分方法的目标数估计对比

Fig. 5 Comparison of target number estimated by three measurement set partition methods




图6 三种量测集划分方法的OSPA距离对比

Fig. 6 Comparison of OSPA distance of three measurement set partition methods

图7对比本文算法、K-means++聚类算法以及距离划分算法在每一时刻量测集的划分数,从而侧面得到这三种算法的计算量对比,可以明显看出量测集划分次数随着目标个数增加而增加。即便如此,本文算法依旧具有更少的量测集划分数,其原因是本文算法为K值设定了取值范围,减小了每一时刻量测集的划分次数,大幅度降低了计算量。




图7 三种量测集划分方法的量测集划分数对比

Fig. 7 Comparison of partition number of three measurement set partition methods

为了验证改进K-means++聚类划分算法在多扩展目标跟踪中降低计算量的有效性,考虑上述跟踪场景,并在Matlab软件上采用50次Monte Carlo仿真进行对比,得到MK-means++、K-means++、DP的平均运行时间分别为72.8571s、155.8325s、178.3981s。由此可见,本文算法的平

均运行时间远远低于K-means++和DP,分别降低了53.25%和59.16%。每一时刻K-means++聚类算法要遍历K值,共需进行 $|Z_k|$ 次划分,其中 $|Z_k|$ 为当前时刻量测集中的量测个数。结合图5,随着目标个数增加,每一时刻量测集划分的次数将呈指数增长,导致整个跟踪过程时间延长。距离划分算法基于两两量测之间的距离阈值集进行量测集划分,每一时刻的距离阈值集中包含的阈值个数为 $|Z_k|(|Z_k|-1)/2$,当量测数大于3时,阈值个数将大于 $|Z_k|$,即随着目标个数增加,每一时刻距离划分算法的量测集划分数将远大于K-means++聚类算法的量测集划分数,大幅度增加了计算量,故需要更长的时间完成所有扩展目标的跟踪。结合图5,本文算法总体量测集划分数低,并且随着目标数增加,本文算法的量测集划分数增加不明显,其原因在于本文算法对K值取值范围进行了合理的限制,进而降低量测集划分次数,大幅度缩短算法的运行时间;同时结合图4可知,本文算法不以牺牲跟踪准确度为代价,在大幅度降低计算量的同时保证了目标跟踪准确度。

本文算法可以根据跟踪的实际场景重新设置K值的上下限,即K值的遍历范围可限制为 $J_{k-1} \leq K \leq J_{k-1} + J_{\text{beta } k} \times J_{k-1} + J_{\text{gam } k}$,其中 $J_{\text{beta } k}$ 表示单个目标可能衍生的目标个数, $J_{\text{gam } k}$ 表示k时刻可能的目标个数,因此改进K-means++聚类划分方法的计算复杂度为 $O((J_{\text{beta } k} \times J_{k-1} + J_{\text{gam } k}) \times |Z_k|)$,而原始K-means++聚类的划分方法的K值遍历范围固定为 $1 \leq K \leq |Z_k|$,其计算复杂度为 $O(|Z_k| \times |Z_k|)$;距离划分方法由于是基于两两量测之间距离的划分方法,要求将两两量测之间的距离作为距离阈值,以此对量测集进行划分,其计算复杂度为 $O(|Z_k| \times (|Z_k| + 1)/2)$ 。

由于 $J_{\text{beta } k} \times J_{k-1}$ 均用 J_{k-1} 近似,而 $J_{\text{beta } k} \times J_{k-1} + J_{\text{gam } k}$ 比 $|Z_k|$ 小,所以本文算法的计算量要比K-means++聚类划分方法低。同理在实际跟踪场景中, $J_{\text{beta } k} \times J_{k-1} + J_{\text{gam } k}$ 往往远小于多扩展目标量测数的一半,那么本文算法的计算量也要比距离划分低。综上,本文算法的计算量要比K-means++聚类的划分方法和距离划分方法低。

综上,根据同一实验条件下所获得仿真性能对比结果可以得到如下结论:本文算法不但可以得到更为准确的目标状态和个数估计,而且因其计算量很低,故而适用于应用资源有限的实时多扩展目标跟踪系统。

5 结语

虽然现有基于距离度量和K-means++聚类的量测集划分方法能在一定程度上提高了跟踪精度,但却是以较高的计算复杂度为代价。针对这一问题,本文提出了一种基于改进K-means++聚类算法的多扩展目标跟踪算法,该方法首先依据下一时刻目标个数可能变化情况,缩小K值遍历范围;然后利用预测状态选取改进K-means++聚类算法的初始中心点,以此遍历K值得到不同的量测集划分结果。实验结果表明:该方法极大程度上提高了K-means++聚类算法的聚类精度,得到比距离划分算法较好的目标跟踪效果,同时其计算量远远低于距离划分算法和K-means++聚类算法。

下一步的研究将针对多个扩展目标相近时由量测集划分不准确而导致的目标个数低估问题提出更有效的方法。近年

来。随着现代传感器分辨率的提高可以得到扩展目标的扩展形态估计,但在多扩展目标跟踪场景中很难同时解决多个扩展目标的跟踪和识别问题,因此,如何快速、有效地实现多扩展目标的联合跟踪和识别会是我们的研究重点。

参考文献 (References)

- [1] VO B N, MA W K. The Gaussian mixture probability hypothesis density filter[J]. IEEE Transactions on Signal Processing, 2006, 54(11): 4091–4104.
- [2] GILHOLM K, SALMOND D. Spatial distribution model for tracking extended objects[J]. IEE Proceedings—Radar, Sonar and Navigation, 2005, 152(5): 364–371.
- [3] GILHOLM K, GODSILL S, MASKELL S, et al. Poisson models for extended target and group tracking[C]// Proceedings of the 2005 Signal and Data Processing of Small Targets, SPIE 5913. Bellingham, WA: SPIE, 2005: 230–241.
- [4] MAHLER R P S. Statistical Multisource-Multitarget Information Fusion[M]. Norwood, MA: Artech House, Inc., 2007: 119–154.
- [5] MAHLER R P S. Multitarget Bayes filtering via first-order multitarget moments[J]. IEEE Transactions on Aerospace and Electronic Systems, 2003, 39(4): 1152–1178.
- [6] ZHANG Y, JI H. A novel fast partitioning algorithm for extended target tracking using a Gaussian mixture PHD filter[J]. Signal Processing, 2013, 93(11): 2975–2985.
- [7] LI Y, XIAO H, SONG Z, et al. A new multiple extended target tracking algorithm using PHD filter[J]. Signal Processing, 2013, 93(12): 3578–3588.
- [8] YANG J, LIU F, GE H, et al. Multiple extended target tracking algorithm based on GM-PHD filter and spectral clustering [J]. EURASIP Journal on Advances in Signal Processing, 2014, 2014(1): No. 117.
- [9] MAHLER R. PHD filters for nonstandard targets, I: extended targets[C]// Proceedings of the 12th International Conference on Information Fusion. Piscataway: IEEE, 2009: 915–921.
- [10] ORGUNER U, LUNDQUIST C, GRANSTRÖM K. Extended target tracking with a cardinalized probability hypothesis density filter [C]// Proceedings of the 14th International Conference on Information Fusion. Piscataway: IEEE, 2011: 1–8.
- [11] GRANSTRÖM K, LUNDQUIST C, ORGUNER O. Extended target tracking using a Gaussian-mixture PHD filter[J]. IEEE Transactions on Aerospace and Electronic Systems, 2012, 48(4): 3268–3286.
- [12] LIAN F, HAN C, LIU W, et al. Unified cardinalized probability hypothesis density filters for extended targets and unresolved targets [J]. Signal Processing, 2012, 92(7): 1729–1744.
- [13] GRANSTRÖM K, LUNDQUIST C, ORGUNER U. A Gaussian mixture PHD filter for extended target tracking[C]// Proceedings of the 13th International Conference on Information Fusion. Piscataway: IEEE, 2010: 1–8.
- [14] 章涛, 来燃, 吴仁彪. 基于观测数据聚类划分的扩展目标跟踪算法[J]. 数据采集与处理, 2017, 32(1): 78–85. (ZHANG T, LAI R, WU R B. Extended target tracking with clustering of measurement partitioning[J]. Journal of Data Acquisition and Processing, 2017, 32(1): 78–85.)
- [15] ARTHUR D, VASSILVITSKII S. K -Means++: the advantages of careful seeding[C]// Proceedings of the 8th Annual ACM-SIAM Symposium on Discrete Algorithms. Philadelphia, PA: Society for Industrial and Applied Mathematics, 2007: 1027–1035.

This work is partially supported by the National “the 13th Five-year” Equipment Pre-Research Foundation of China (61403120207), the National Defense Basic Scientific Research Program of China (JCKY2018419C001), the Aeronautical Science Foundation of China (20185142003), the National Natural Science Foundation of China (U1504619, 61671139), the Scientific Technology Program of Henan Province (182102110397, 192102210064, 172002310636), the Support Plan for the Science and Technology Innovative Teams in University of Henan Province (18IRTSTHN011).

YU Haofang, born in 1995, M. S. candidate. Her research interests include multiple target tracking, extended object tracking.

SUN Lifan, born in 1982, Ph. D., associate professor. His research interests include multiple extended object tracking, multi-sensor information fusion.

FU Zhumu, born in 1974, Ph. D., professor. His research interests include uncertainty information processing, machine vision.